

Pemodelan dan desain sekuens dari skala molekuler hingga genom dengan Evo

Eric Nguyen^{*1,2}, Michael Poli^{*3}, Matthew G. Durrant^{*2}, Armin W. Thoma^{s1}, Brian Kang¹, Jeremy Sullivan², Madelena Y. Ng¹, Ashley Lewis¹, Aman Patel¹, Aaron Lou¹, Stefano Ermon^{1,4}, Stephen A. Baccus¹, Tina Hernandez-Boussard¹, Christopher Ré¹, Patrick D. Hsu^{†,2,5}, dan Brian L. Hie^{†,1,2}

1Stanford University, 2Arc Institute, 3TogetherAI, 4CZ Biohub, 5Universitas California, Berkeley

Abstrak

Genom adalah sekuens yang sepenuhnya menyandikan DNA, RNA, dan protein yang mengatur fungsi keseluruhan organisme. Kemajuan dalam pembelajaran mesin yang digabungkan dengan himpunan data masif genom utuh dapat memungkinkan model fondasi biologis yang mempercepat pemahaman mekanistik dan desain generatif interaksi molekuler kompleks. Kami melaporkan Evo, model fondasi genomik yang memungkinkan tugas prediksi dan generasi dari skala molekuler hingga genom. Menggunakan arsitektur berbasis kemajuan dalam pemrosesan sinyal dalam, kami meningkatkan skala Evo menjadi 7 miliar parameter dengan panjang konteks 131 kilobasa (kb) pada resolusi nukleotida tunggal, byte. Dilatih pada 2.7 juta genom prokariotik dan fag, Evo mampu menggeneralisasi ketiga modalitas dasar dogma sentral biologi molekuler untuk melakukan prediksi fungsi zero-shot yang kompetitif dengan, atau melampaui, model bahasa spesifik-domain terkemuka. Evo juga unggul dalam tugas generasi multi-elemen, yang kami demonstrasikan dengan menghasilkan kompleks molekuler CRISPR-Cas sintetik dan seluruh sistem transposabel untuk pertama kalinya. Menggunakan informasi yang dipelajari dari genom utuh, Evo juga dapat memprediksi esensialitas gen pada resolusi nukleotida dan dapat menghasilkan sekuens kaya pengode hingga sepanjang 650 kb, beberapa orde magnitudo lebih panjang dibandingkan metode sebelumnya. Kemajuan dalam pembelajaran multi-modal dan multi-skala dengan Evo memberikan jalur yang menjanjikan menuju peningkatan pemahaman dan kendali kita terhadap biologi di berbagai tingkat kompleksitas.

1. Pendahuluan

DNA adalah lapisan dasar informasi biologis yang bertanggung jawab mentransmisikan hasil evolusi melintasi generasi kehidupan (Morgan, 1910; Watson dan Crick, 1953; Nirenberg dan Matthaei, 1961). Variasi evolusioner dalam sekuens genom merupakan cerminan adaptasi dan seleksi untuk fungsi biologis pada tingkat fenotipik (Dobzhansky, 1951). Kemajuan pesat dalam teknologi sekuensing DNA telah memungkinkan pemetaan sistematis keanekaragaman evolusioner ini pada skala seluruh genom.

Sebuah mesin yang mempelajari cakupan informasi seluas ini di seluruh genom dapat memodelkan fungsi DNA, RNA, dan protein, serta interaksi beragamnya yang mengorkestrasi fungsi biologis kompleks, memediasi penyakit, atau menciptakan organisme yang utuh. Algoritme pembelajaran mesin modern yang dikombinasikan dengan kumpulan data masif sekuens genomik dapat memungkinkan suatu model dasar biologis umum yang mempelajari logika intrinsik keseluruhan genom.

Namun, upaya terkini untuk memodelkan biologi molekuler dengan pembelajaran mesin telah berfokus pada pembuatan model spesifik-modalitas yang dikhususkan untuk protein, DNA regulator, atau RNA (Jumper et al., 2021; Rives et al., 2021; Avsec et al., 2021; Theodoris et al., 2023). Selain itu, aplikasi generatif dalam biologi telah terbatas pada desain molekul tunggal, kompleks sederhana (Watson et al., 2023; Madani et al., 2023;

*Equal contribution. †Corresponding author. B.L.H. (brianhie@stanford.edu); P.D.H. (patrick@arcinstitute.org).




Figure 1 | Prapeltihan model fondasi genomik di seluruh kehidupan prokariotik. (A) Model sekuens genom pada resolusi nukleotida tunggal dapat mempelajari semua informasi yang dikodekan dalam DNA regulatori dan dalam sekuens modalitas lainnya di dalam dogma sentral (protein, RNA pengkode, dan RNA nonpengkode). Lebih jauh lagi, model tersebut dapat mempelajari kovariansi yang melibatkan banyak gen dan elemen regulatori. Status DNA sebagai lapisan fundamental informasi biologis menjadikannya modalitas yang produktif untuk mengembangkan model fondasi biologis. (B) Model yang memprediksi kemungkinan token berikutnya berdasarkan sekuens token, yang disebut pemodelan autoregresif, dapat mempelajari pola-pola kompleks yang mendasari sekuens DNA. StripedHyena adalah arsitektur pemrosesan sinyal mendalam untuk sekuens panjang, yang diperoleh dengan menghibridisasi operator atensi dan hyena. (C) Kami melakukan prapeltihan Evo, model berparameter 7B dengan arsitektur StripedHyena, pada sekuens genom bakteri dari GTDB dan IMG/PR serta sekuens virus dari IMG/VR, dengan mengecualikan sekuens dari virus yang menginfeksi inang eukariotik. (D) Histogram yang menggambarkan panjang sekuens genom di GTDB. mb: megabase. (E) Diagram lingkaran yang menggambarkan komposisi taksonomi GTDB berdasarkan kingdom (kiri) dan filum (kanan). (F) Hasil dari analisis hukum penskalaan pertama dari jenisnya untuk prapeltihan DNA skala besar. Model meningkat secara monoton seiring skala, dengan perbedaan signifikan antar arsitektur. Eval. PPL: perplexity evaluasi. (G) Untuk menentukan arsitektur dan penskalaan optimal bagi Evo, kami membandingkan laju penskalaan berbagai model yang dipelajari pada frontier optimal komputasi, yaitu dengan alokasi komputasi yang optimal antara ukuran dataset dan ukuran model. Eval. PPL: perplexity evaluasi. FLOPs: operasi floating point.

Ingraham et al., 2023), atau sekuens DNA pendek (DaSilva et al., 2024; Lal et al., 2024). Sebaliknya, proses biologis yang kompleks, seperti regulasi gen, imunitas CRISPR, atau transposisi genetik, bergantung pada banyak interaksi yang melibatkan molekul dari berbagai modalitas.

Sebuah model DNA yang menyatukan informasi di seluruh skala molekuler, sistem, dan genom dapat belajar dari wilayah genomik besar untuk menangkap interaksi seluruh sistem dan memungkinkan perancangan fungsi biologis yang lebih canggih. Dengan beroperasi pada resolusi nukleotida tunggal, model ini akan mampu menggabungkan efek evolusioner dari variasi sekuens, seperti mutasi nukleotida tunggal individual yang sepenuhnya mengubah fungsi organisme.

Terinspirasi oleh kesuksesan model bahasa besar baru-baru ini, banyak pendekatan kontemporer memanfaatkan Transformer autoregresif untuk memodelkan sekuens biologis dan menangkap interaksi seluruh sistem ini. Namun, upaya yang ada untuk memodelkan DNA sebagai suatu bahasa (Zvyagin et al., 2023; Dalla-Torre et al., 2023; Zhou et al., 2023) dibatasi oleh arsitektur Transformer padat yang lazim, yang menimbulkan biaya komputasi tinggi seiring bertambahnya panjang sekuens masukan relatif terhadap lebar model (berskala kuadratik) dan umumnya berkinerja lebih rendah pada resolusi nukleotida tunggal atau tingkat byte (dibandingkan dengan model yang dilatih pada resolusi yang lebih kasar) (Tay et al., 2021). Kemajuan algoritmik terkini dalam memperpanjang panjang konteks model berbasis atensi (Chen et al., 2023; Liu et al., 2023) memiliki keterbatasan resolusi yang serupa. Akibatnya, model DNA berbasis Transformer terbatas pada panjang konteks yang pendek dan menggunakan skema yang mengagregasi nukleotida menjadi unit dasar model bahasa, yang disebut token, sehingga mengorbankan resolusi nukleotida tunggal (Zvyagin et al., 2023; Dalla-Torre et al., 2023; Fishman et al., 2023; Ji et al., 2021; Hwang et al., 2023).

Di sini, kami memaparkan Evo, sebuah model fondasi genomik dengan 7 miliar parameter yang dilatih untuk menghasilkan sekuens DNA pada skala genom penuh. Evo menggunakan panjang konteks 131k token dan didasarkan pada arsitektur StripedHyena (Poli et al., 2023b), yang menggabungkan operator atensi dan konvolusional yang dikendalikan data untuk memproses dan mengingat pola secara efisien dalam sekuens panjang. Evo dilatih pada set data genom penuh prokariotik yang terdiri dari 300 miliar nukleotida dan menggunakan tokenizer berbasis bita, nukleotida tunggal.

Kami mendemonstrasikan bahwa Evo dapat digunakan dalam tugas prediksi dan generasi pada skala molekuler, sistem, dan genom. Dalam evaluasi zero-shot, Evo bersaing dengan model bahasa protein terkini dalam memprediksi efek kebugaran mutasi pada *E. coli* protein, mengungguli model bahasa RNA khusus dalam memprediksi efek kebugaran mutasi pada RNA nonpenyandi, dan memprediksi kombinasi pasangan promotor prokariotik-situs pengikatan ribosom (RBS) yang menghasilkan ekspresi gen aktif hanya dari sekuens regulatorik. Melampaui molekul tunggal dan sekuens pendek, Evo mempelajari keterkaitan koevolusioner sekuens penyandi dan nonpenyandi untuk merancang sistem biologi multikomponen sintetik termasuk sistem CRISPR-Cas dan elemen transposabel. Pada skala genom keseluruhan, Evo dapat memprediksi gen esensial pada bakteri atau bakteriofag tanpa supervisi apa pun. Kami juga menggunakan Evo untuk menghasilkan sekuens sepanjang lebih dari 650 kilobasa (kb) dengan arsitektur pengodean genomik yang masuk akal, suatu skala yang beberapa orde magnitudo lebih besar daripada metode sebelumnya (DaSilva et al., 2024; Lal et al., 2024; Watson et al., 2023). Secara keseluruhan, Evo menetapkan paradigma dasar untuk pemodelan sekuens biologis prediktif dan generatif (Gambar 1A). Pengembangan Evo lebih lanjut akan memungkinkan pemahaman mekanistik yang lebih dalam tentang biologi dan mempercepat kemampuan kita untuk merekayasa kehidupan.

2. Hasil

2.1. Pemodelan sekuens panjang pada resolusi nukleotida dengan arsitektur StripedHyena

Evo adalah model fondasi genomik dengan 7B parameter yang dilatih dengan panjang konteks hingga 131k token, menggunakan tokenisasi nukleotida tunggal pada aras bita. Untuk memodelkan sekuens panjang pada resolusi nukleotida secara efisien, yang kami demonstrasikan dengan membangkitkan sekuens melebihi 650k token, kami memanfaatkan arsitektur StripedHyena (Poli et al., 2023b) (Gambar 1B) yang dibangun berdasarkan teknik yang sedang berkembang dalam pemrosesan sinyal mendalam (Li et al., 2020; Gu et al., 2021; Orvieto et al., 2023; Massaroli et al., 2024). Model ini merupakan hibrida dari 29 lapis operator konvolusional terkendali data (lapisan hyena) yang diselingi dengan 3 lapis (10%) atensi multi-kepala yang dilengkapi dengan penyematan posisi berotasi (RoPE) (Su et al., 2024) (Metode).

Hibridisasi model, yang pertama kali diusulkan untuk mengatasi kekurangan model ruang keadaan (Ma et al., 2022; Fu et al., 2022; Pilault et al., 2024), baru-baru ini terbukti meningkatkan kinerja penyekalaan dalam pemodelan bahasa baik pada arsitektur Hyena mandiri maupun Transformer (Poli et al., 2023b). StripedHyena dirancang untuk mendapatkan manfaat dari spesialisasi setiap jenis lapisannya, dengan lapisan hyena menerapkan sebagian besar kom-

putasi yang diperlukan untuk pemrosesan sekuens dan lapisan atensi yang melengkapi kemampuan untuk mengingat informasi dari konteks suatu masukan.

Lapisan Hyena memproses sekuens secara bergantung pada masukan melalui komposisi filter konvolusi pendek dan panjang (Figure 1B), menjadikan lapisan ini sangat efektif dalam menyaring pola bising yang dapat terjadi pada DNA dan mengagregasi nukleotida individu menjadi motif. Dibandingkan dengan HyenaDNA (Nguyen et al., 2023), generasi sebelumnya dari model DNA yang memanfaatkan arsitektur Hyena (Poli et al., 2023a), Evo didasarkan pada desain hibrida yang ditingkatkan dan diskalakan hingga ukuran model 1000× kali lebih besar dan data 100× kali lebih banyak.

2.2. Pelatihan Evo pada skala besar pada OpenGenome

Kami menyusun kumpulan data genom besar yang disebut OpenGenome (Metode) dengan lebih dari 80,000 genom bakteri dan arkea, serta jutaan sekuens fag prokariotik dan plasmid yang diprediksi, yang mencakup 300B token nukleotida (Gambar 1C dan S1) (Parks et al., 2022; Camargo et al., 2023, 2024). Untuk pertimbangan keamanan, kami mengecualikan genom virus yang menginfeksi inang eukariotik. Seperti kebanyakan model bahasa, Evo dipelajari melalui tugas prediksi token-berikutnya pada sekuens genom mentah tanpa pengawasan atau anotasi eksplisit. Untuk mempelajari distribusi data genom dan menyadari motif sekuens biologis yang ditemukan dalam genom yang dikumpulkan. Pelatihan mencakup 2 tahap: tahap pertama menggunakan panjang konteks 8k token, sedangkan tahap kedua perluasan konteks menggunakan 131k token sebagai konteks. Bergantung pada tugas hilir, kami memilih model dasar dari salah satu dari dua tahap tersebut untuk menyelenggarakan pada kumpulan data yang lebih kecil yang diminati untuk generasi.

2.3. StripedHyena menunjukkan hukum penskalaan yang menguntungkan pada sekuens DNA

Untuk membantu desain model kami, kami melakukan analisis hukum penskalaan pertama (sepanjang pengetahuan kami) untuk pemodelan sekuens DNA. Tujuan utama dari jenis analisis ini adalah untuk menentukan hubungan antara pelatihan, detail arsitektur, dan metrik kinerja melalui protokol eksperimental yang sistematis (Hoffmann et al., 2022; Kaplan et al., 2020). Setelah seperangkat hukum penskalaan diperoleh, hukum tersebut kemudian dapat digunakan sebagai panduan untuk menskalakan pelatihan secara optimal ke model dan kumpulan data yang lebih besar.

Di sini, kami membandingkan berbagai kelas arsitektur melalui protokol optimal komputasi, yang bertujuan untuk mengevaluasi hasil pada *compute-optimal frontier* (Metode). Kami melatih lebih dari 300 model di empat arsitektur: Transformer++, Mamba, Hyena, dan StripedHyena. Transformer++ adalah Transformer mutakhir, dan Mamba adalah arsitektur modern yang menggunakan model ruang-keadaan terkendali data (Gu dan Dao, 2023).


Kami menemukan bahwa Transformer++ menghasilkan perplexity yang jauh lebih buruk (ukuran kualitas prediksi token berikutnya) pada semua anggaran komputasi (Gambar 1G), suatu gejala ketidakefisienan arsitektur pada resolusi bit. Arsitektur state-space dan pemrosesan sinyal dalam teramati meningkatkan laju penskalaan dibandingkan Transformer++, dengan Hyena dan StripedHyena menghasilkan laju penskalaan terbaik. Kami mengamati pelatihan yang stabil untuk StripedHyena di seluruh ukuran model dan laju pembelajaran yang dikaji selama analisis penskalaan.

Kami juga membandingkan performa arsitektur di luar batas depan optimal komputasi, yaitu dengan alokasi anggaran komputasi yang mungkin suboptimal. Performa di luar batas depan optimal komputasi penting dalam praktik, karena sebagian besar model (termasuk Evo) dilatih dengan lebih banyak token daripada yang direkomendasikan oleh hukum penskalaan optimal komputasi. Kami memperkirakan 250 miliar sebagai jumlah token optimal komputasi untuk Evo 7B berdasarkan anggaran FLOP, yang berarti model dilatih pada offset 17% dari ukuran model optimal komputasi selama fase prapenelitian awal dengan panjang sekuens 8.192 token sebanyak 300 miliar token. Baik Transformer++ maupun Mamba mengalami ketidakstabilan numerik selama pelatihan, dan mengalami penurunan performa yang lebih tajam pada laju penskalaan di luar batas depan optimal komputasi, berbeda dengan StripedHyena (analisis lebih lanjut pada Gambar S3). Temuan ini memotivasi pemilihan StripedHyena sebagai arsitektur untuk Evo.

2.4. Evo melakukan prediksi fungsi zero-shot di seluruh modalitas DNA, RNA, dan protein

2.4.1. Predicting mutational effects on protein function

Selain mengevaluasi perplexity, kami menyelidiki performa zero-shot model pada hal yang relevan secara biologis tugas hilir. Sebagai contoh, model bahasa yang dilatih secara spesifik pada korpus besar urutan protein sekuens pengkode nukleotida telah menunjukkan kemampuan yang mengesankan untuk memprediksi efek mutasi pada pro-



Gambar 2 | Evo melakukan prediksi fungsi zero-shot untuk protein, RNA non-pengkode, dan DNA regulatori. (A) Kami memperoleh set data pemindaian mutasi mendalam (DMS) di mana banyak mutasi dibuat pada suatu protein dan skor kebugaran yang sesuai diukur secara eksperimental untuk setiap varian protein. Pada set sekuens termutasi yang sama, kami menghitung likelihood (atau pseudolikelihood)-nya di bawah model bahasa protein atau model bahasa nukleotida (LM). Kami kemudian mengorelasikan likelihood ini dengan pengukuran kebugaran eksperimental dan menggunakan kekuatan korelasi tersebut untuk mengukur kinerja prediksi fungsi zero-shot. (B) Evo memiliki kinerja prediksi yang sebanding, diukur melalui korelasi Spearman, dengan model bahasa protein termutakhir dan kinerja lebih tinggi daripada model bahasa nukleotida. Tinggi batang menunjukkan rerata; setiap titik menunjukkan studi DMS yang berbeda. LM: model bahasa; Nucl. Trans.: Nucleotide Transformer. (C) Kami memperoleh set data di mana banyak mutasi dibuat pada suatu ncRNA dan skor kebugaran yang sesuai diukur secara eksperimental. Kinerja prediksi diukur seperti pada metode yang dijelaskan di (A). (D) Evo menunjukkan kinerja lebih tinggi daripada model bahasa nukleotida dalam memprediksi efek mutasi pada fungsi ncRNA. Tinggi batang menunjukkan rerata; setiap titik menunjukkan studi DMS yang berbeda. LM: model bahasa; Nucl. Trans.: Nucleotide Transformer. (E) Kami memperoleh set data di mana Kosuri et al. (2013) mengukur ekspresi mRNA dan protein dari suatu gen di hilir ~12k pasangan promoter-RBS pada *E. coli*. Untuk setiap pasangan promoter-RBS, kami menghitung likelihood sekuens di bawah model bahasa atau suatu skor yang menunjukkan frekuensi kemunculan pasangan promoter-RBS dalam genom bakteri. (F, G) Evo memiliki kinerja prediksi ekspresi mRNA dan protein yang lebih tinggi dibandingkan model bahasa nukleotida dan metode penghitungan frekuensi pasangan promoter-RBS berdasarkan penyejajaran sekuens ("Seq. align."). Tinggi batang menunjukkan rerata; setiap titik menunjukkan studi DMS yang berbeda. LM: model bahasa; Nucl. Trans.: Nucleotide Transformer.

fungsi protein (Meier et al., 2021; Notin et al., 2022; Benegas et al., 2023) tanpa penyempurnaan atau supervisi khusus tugas. Karena Evo dilatih pada sekuens genomik panjang yang mengandung sekuens pengkode protein, kami menguji apakah model ini juga akan mempelajari bahasa protein dengan cukup baik untuk melakukan prediksi fungsi protein zero-shot.

Mengikuti penelitian dalam evaluasi model bahasa protein, kami memanfaatkan studi pemindaian mutasi mendalam (DMS) yang memperkenalkan satu set mutasi yang lengkap pada suatu sekuens penyandi protein dan kemudian mengukur secara eksperimental efek mutasi tersebut pada berbagai definisi kebugaran (kebugaran adalah metrik spesifik studi yang mengukur seberapa baik suatu protein menjalankan fungsi tertentu) (Notin et al., 2022, 2023; Livesey and Marsh, 2023). Likelihood atau pseudolikelihood model bahasa (Metode) dari sekuens asam amino digunakan untuk memprediksi skor kebugaran eksperimental (Figure 2A). Untuk menyesuaikan tugas ini pada sekuens nukleotida, kami menggunakan sekuens penyandi tipe liar dan mutasi nukleotida yang dilaporkan dalam studi DMS asli (Metode).

Ketika kami mengevaluasi kemampuan zero-shot Evo untuk memprediksi efek mutasional pada fungsi protein menggunakan himpunan data DMS dari *E. coli* protein, kami menemukan bahwa Evo mengungguli semua model nukleotida lain yang diuji (Gambar 2B), termasuk GenSLM (Zvyagin et al., 2023), suatu model yang secara eksplisit dilatih hanya pada sekuens pengode dengan kosakata kodon (Gambar 1A). Evo juga mencapai kinerja yang kompetitif dengan model bahasa spesifik-protein terkemuka (Yang et al., 2024; Meier et al., 2021; Lin et al., 2023; Madani et al., 2023) pada tugas ini (Gambar 2B). Penelitian sebelumnya telah menunjukkan bahwa peningkatan melampaui rentang kinerja ini sangat sulit bagi model bahasa protein hanya dengan prapelatihan swa-awas saja (Li et al., 2024), yang mengindikasikan bahwa Evo telah kompetitif dengan pemodelan bahasa protein terkini pada protein bakteri. Secara khusus, Evo dilatih pada sekuens genomik konteks panjang tanpa anotasi sekuens pengode eksplisit. Pada himpunan data DMS protein manusia, Evo tidak mampu memprediksi efek mutasional terhadap kebugaran (Gambar S6A), kemungkinan besar karena himpunan data prapelatihan hanya berisi sekuens prokariotik. Namun, kami mengamati asosiasi yang kuat antara perplexitas model bahasa pada sekuens tipe liar dan kinerja prediksi kebugaran (Gambar S6B), yang menunjukkan bahwa penyesuaian lanjut atau prapelatihan mendatang pada sekuens pengode mamalia dapat meningkatkan kinerja Evo melampaui protein bakteri.

2.4.2. Predicting mutational effects on ncRNA function

Selanjutnya, kami menguji apakah model prapelatihan yang sama dapat mempelajari informasi fungsional tentang RNA nonkode (ncRNA), seperti tRNA, rRNA, dan ribozim. ncRNA disandi dalam genom dengan cara yang serupa dengan protein dan menjalankan berbagai fungsi esensial, termasuk dalam sintesis protein dan regulasi gen. Kami mengumpulkan data DMS ncRNA (Metode), yang secara konseptual mirip dengan himpunan data DMS protein, tetapi mutasi dibuat pada sekuens ncRNA. Kami juga mengevaluasi kemampuan Evo dalam melakukan prediksi kebugaran ncRNA secara zero-shot dengan menggunakan hasil studi DMS ncRNA eksperimental sebagai skor kebenaran dasar (Gambar 2C).

Kami menemukan bahwa Evo kembali mengungguli semua model bahasa nukleotida lain yang diuji pada tugas ini, termasuk RNA-FM (Chen et al., 2022), model bahasa RNA yang secara eksplisit dilatih pada sekuens ncRNA (Gambar 2D). Kami mengamati kinerja prediktif yang sangat kuat pada studi yang mengukur efek mutasi pada RNA ribosom 5S terhadap laju pertumbuhan *E. coli* (Spearman $r = 0,64$, dua sisi t -terdistribusi $P = 7.3 \times 10^{-4}$) (Zhang et al., 2009). Bersama dengan hasil kami untuk sekuens protein, hasil ini menunjukkan bahwa Evo mampu belajar dari data pelatihan genom prokariotiknya untuk memprediksi sifat-sifat fungsional lintas modalitas molekuler yang berbeda.

2.4.3. Predicting gene expression from regulatory DNA

Mengingat Evo juga dilatih pada sekuens DNA regulatorik prokariotik selain sekuens yang mengkode protein atau ncRNA, kami menyelidiki apakah Evo mampu mempelajari aspek tata bahasa regulatorik DNA. Untuk tujuan ini, kami memanfaatkan dataset di mana Kosuri et al. (2013) mengonstruksi sekitar 12 ribu kombinasi promotor umum dan situs pengikatan ribosom (RBS) serta mengukur ekspresi mRNA dan protein yang sesuai dari suatu gen reporter untuk setiap pasangan promotor-RBS pada *E. coli* (Gambar 2E). Kami menemukan bahwa skor likelihood model yang diberikan Evo pada sekuens promotor-RBS berkorelasi secara signifikan dengan ekspresi mRNA (Spearman $r = 0,41$, dua sisi $P < 1 \times 10^{-5}$) (Gambar 2F) dan bersifat prediktif terhadap ekspresi protein yang dibinarkan (area di bawah kurva karakteristik operasi penerima [AUROC] = 0,68, berbasis permutasi $P < 1 \times 10^{-5}$) (Gambar 2G) (Metode). Kinerja prediktif Evo juga secara substansial lebih tinggi dibandingkan model bahasa nukleotida lainnya, meskipun tidak satu pun dari model bahasa baseline ini telah dilatih pada dataset

mengandung elemen pengatur.

Untuk memprediksi ekspresi gen hanya dari urutan promoter-RBS, Evo kemungkinan besar menggunakan pengetahuan tentang urutan regulator alami yang dipelajari selama pra-pelatihan, serupa dengan bagaimana model bahasa protein dapat memprediksi perubahan fungsional berdasarkan variasi alami pada urutan protein (Meier et al., 2021; Notin et al., 2023). Untuk tujuan ini, sebagai tolok ukur tambahan, kami menyelaraskan pasangan promoter-RBS dengan set data pra-pelatihan model kami yang berisi urutan prokariotik. Meskipun kami menghipotesiskan bahwa jumlah atau kekuatan penyelarasan ini akan bersifat prediktif terhadap ekspresi gen, kami menemukan bahwa menghitung penyelarasan ini menggunakan perangkat bioinformatika standar menghasilkan kecocokan urutan yang buruk atau tidak ada (Metode). Dari semua teknik yang kami coba, tidak ada yang bersifat prediktif terhadap ekspresi gen (Gambar 2F dan 2G), yang menunjukkan bahwa Evo dapat menyaring informasi fungsional non-jelas dari DNA regulator secara langsung dari pangkalan data urutan genomik yang besar.

Secara keseluruhan, kami menunjukkan bagaimana sebuah model fondasi tunggal untuk genom prokariotik dapat melakukan tugas-tugas yang sebelumnya diselesaikan oleh berbagai model spesifik-domain (model bahasa protein, model bahasa RNA, dan model DNA regulatoris). Meskipun dilatih pada potongan genom panjang tanpa anotasi urutan eksplisit, Evo tetap menunjukkan pemahaman akan urutan pengode protein konstitutif, urutan ncRNA, dan elemen regulatoris.

2.5. Desain generatif kompleks molekuler CRISPR-Cas

Selanjutnya, kami berargumen bahwa Evo seharusnya mampu menghasilkan kompleks fungsional yang melibatkan interaksi antara modalitas molekuler yang berbeda. Pada prokariota, gen yang terkait secara fungsional umumnya terletak bersebelahan pada sekuens genom linear. Karena Evo mempelajari pola kovariasi yang melibatkan elemen genetik apa pun di dalam jendela konteksnya, model ini seharusnya memahami interaksi antara molekul protein yang dikodekan dan ncRNA. Untuk menunjukkan kemampuan ini, kami melakukan fine-tuning pada Evo menggunakan dataset locus genomik yang mengandung sekuens CRISPR-Cas: mesin molekuler yang terdiri dari satu atau lebih komponen protein dan satu atau lebih komponen ncRNA yang, secara bersama-sama, mengarahkan kekebalan adaptif terhadap infeksi virus (Wang et al., 2022).

Nuklease Cas9 penarget DNA umumnya disandi dalam 3.000 hingga 4.800 bp sekuens pengkode dan ditemukan dalam kedekatan genomik dengan susunan CRISPR kognatnya (Hsu et al., 2014). Transkripsi dari susunan CRISPR menghasilkan molekul RNA CRISPR non-pengkode (crRNA) yang diikat oleh protein Cas untuk membentuk kompleks pertahanan fungsional yang diperlukan untuk penargetan DNA spesifik-sekuens (Gambar 3A). Khusus untuk Cas9, RNA CRISPR trans-aktivasi (tracrRNA) kedua membentuk dupleks dengan crRNA untuk menghasilkan RNA pemandu lengkap (gRNA). Beragam famili sistem CRISPR-Cas ditemukan di seluruh kehidupan bakteri dan arkea, seperti sistem berbasis Cas12 atau Cas13 yang masing-masing menargetkan DNA dan RNA (Koonin dan Makarova, 2019).

Pada tahap fine-tuning, kami melatih model pada 82.430 locus CRISPR-Cas yang diekstraksi dari sekuens metagenomik dan genomik publik, dengan menambahkan token prompt khusus untuk Cas9, Cas12, dan Cas13 yang ditambahkan di awal setiap sekuens pelatihan (Gambar 3B). Selama proses sampling, token-token ini memungkinkan kami memandu pembangkitan tipe sistem CRISPR-Cas tertentu dengan memberikan prompt menggunakan token khusus yang sesuai. Menariknya, sampling sekuens sepanjang 8 kb menggunakan masing-masing dari ketiga token prompt Cas menghasilkan generasi yang koheren. Bergantung pada token prompt yang digunakan, 15-45% generasi mengandung sekuens pengkode Cas hingga sepanjang 5kb sebagaimana terdeteksi oleh HMM profil sub tipe Cas (Metode). Kami juga mengamati bahwa pemberian prompt dengan token sub tipe Cas tertentu biasanya menghasilkan sampel dengan sub tipe yang diharapkan, menunjukkan bahwa Evo dapat disetel untuk menghasilkan sekuens dengan protein yang diinginkan maupun elemen non-pengkode terkait seperti susunan CRISPR (Gambar 3C). Penjajaran sekuens dengan dataset pelatihan mengungkapkan bahwa Evo mampu menghasilkan generasi protein Cas yang sangat unik, karena beberapa ORF yang diprediksi menunjukkan identitas sekuens protein kurang dari 40% terhadap kecocokan terdekatnya masing-masing (Gambar 3D dan S7).

Untuk mengevaluasi kualitas generasi Cas dengan Evo, kami berfokus pada generasi Cas9 dan mengevaluasi prediksi struktur AlphaFold2 dari sekuens penyandi Cas9 yang disampel dan kompleks RNA non-penyandi terhadap struktur yang ditentukan secara eksperimental dari protein Cas9 *Streptococcus pyogenes* dan dupleks tracrRNA:crRNA-nya. Prediksi struktur terpilih dari sekuens Cas9 yang disampel menunjukkan bahwa bahkan generasi dengan identitas rendah memiliki kemiripan dengan struktur Cas9 alami pada domain-domain kunci seperti nuklease RuvC dan domain yang berinteraksi dengan motif yang berdekatan dengan protospacer (PAM) (Figure 3E). Secara serupa, dupleks crRNA:tracrRNA yang dihasilkan oleh Evo membentuk struktur sekunder RNA yang diprediksi menyerupai dupleks crRNA:tracrRNA kanonik yang ditemukan pada sistem Cas9 alami (Figure 3F) (Gasiunas et al., 2020).




Figure 3 | Penyetelan lanjut pada sekuens CRISPR-Cas memungkinkan desain generatif kompleks protein-RNA. (A) Nuklease pertahanan CRISPR-Cas terdiri dari kompleks makromolekul besar yang melibatkan protein efektor yang terikat pada RNA pemandu nonkode (gRNA) yang berasal dari RNA CRISPR (crRNA). Untuk beberapa tipe CRISPR, RNA CRISPR pengaktif trans (tracrRNA) digabungkan dengan crRNA untuk membentuk gRNA akhir. Tugas desain kami adalah menghasilkan sekuens yang mengandung komponen protein dan RNA nonkode ini. (B) Kami menyetel lanjut Evo, setelah fase prapelatihan awal 8k, pada sekuens genomik sepanjang 8 kb yang mengandung sistem CRISPR-Cas. Selama penyetelan lanjut, kami menambahkan token pengkondisian khusus ("cas9," "cas12," atau "cas13") di awal setiap sekuens, yang menunjukkan tipe umum protein Cas yang dikodekan dalam sekuens tersebut. (C) Token prompt memungkinkan pengendalian atas generasi Evo. Saat memberikan prompt dengan token untuk tipe protein Cas tertentu, protein Cas paling umum yang ditemukan dalam sekuens yang dihasilkan sesuai dengan token prompt tersebut (misalnya, memberikan prompt dengan token "cas9" biasanya menghasilkan sekuens Cas9). (D) Histogram yang merepresentasikan distribusi persentase identitas sekuens protein Cas yang dihasilkan terhadap sekuens protein Cas mana pun dalam dataset pelatihan. Distribusi ini dihitung di seluruh proses pengambilan sampel yang melibatkan ketiga prompt. (E) Generasi representatif protein Cas bersama dengan *S. pyogenes* struktur kristal Cas9 (PDB: 4OO8). AF2: AlphaFold2. REC: lobus pengenalan. NUC: lobus nuklease. (F) Contoh generasi dupleks crRNA:tracrRNA bersama dengan kanonik *S. pyogenes* dupleks Cas9.

Ketika disetelhaluskan pada sistem CRISPR-Cas, Evo dapat menghasilkan sampel beragam secara koheren yang menyerupai sistem Cas yang muncul secara alami baik dalam urutan maupun struktur. Perancangan sistem Cas baru secara historis bergantung pada penambahan basis data urutan untuk protein homolog, di mana evolusi alami menyediakan keragaman fungsional. Pemodelan generatif dengan Evo menyediakan metodologi perancangan alternatif yang dapat dimanfaatkan di seluruh aplikasi luas teknologi CRISPR.

2.6. Desain generatif sistem biologis yang dapat ditransposisikan

Selain kompleks molekuler, Evo dapat mempelajari pola yang mendasari sistem multi-gen. Contoh sistem replikasi minimal adalah elemen genetis bergerak (MGEs), yang ditemukan di seluruh domain kehidupan. Penyebaran oportunisiknya memberikan kekuatan fundamental yang mendorong variasi sekuens, fungsi gen baru, dan bahkan spesiasi (Chandler et al., 2020). Elemen sekuens insersi (IS) adalah MGEs kompak yang umumnya hanya mengkodekan komponen yang diperlukan untuk transposisi. Kelompok IS605 tersebar luas di prokariota dan terdiri dari tiga komponen kunci: transposase TnpA yang mengkatalisis transposisi lepaskan-dan-tempel di samping nuklease TnpB yang dipandu RNA dan ω RNA kognatnya yang mendorong pewarisan egois elemen transposabel tersebut (Gambar 4A) (Meers et al., 2023; Karvelis et al., 2021; Altae-Tran et al., 2021). Kelompok IS605 termasuk dalam famili IS200/IS605 yang lebih besar, yang mencakup elemen kelompok IS200 yang tidak memiliki endonuklease TnpB. Meningkatkan pemahaman kita tentang fungsi biologisnya dan menghasilkan MGEs baru dengan sifat yang diinginkan dapat menghasilkan perangkat rekayasa genom yang lebih efektif.


Kami menyempurnakan Evo pada 10.720 elemen IS605 dan 219.867 elemen IS200 dalam konteks sekuens alamin ya dan menggunakan model tersebut untuk menghasilkan elemen IS200/IS605 baru (Gambar 4B) (Metode). Dengan berfokus pada sekuens yang dihasilkan yang mengandung sekuens pengode TnpA dan TnpB yang diprediksi, kami berhasil mendeteksi banyak sekuens yang menyandi protein yang berbeda secara substansial dari set pelatihan, dengan 2.5% protein TnpA memiliki identitas <50% terhadap set pelatihan, dan 90.1% protein TnpB (Gambar 4C dan S8). Kami menemukan bahwa 87.6% protein TnpA yang dihasilkan melipat dengan baik dengan pLDDT ESMFold > 70, dibandingkan dengan 25.5% protein TnpB, yang mungkin disebabkan oleh kelimpahan protein TnpA yang lebih besar dalam set pelatihan. Melalui anotasi dan pemeriksaan contoh individual, kami menemukan bahwa beberapa lokus yang beragam menyandi protein transposase dan nuklease yang koheren yang melipat dengan baik menggunakan ESMFold, sangat cocok dengan struktur yang ditentukan secara eksperimental dari protein homolog, dan juga mengandung sekuens ω RNA yang diprediksi (nilai-E cmsearch = 5.6×10^{-12} ; Gambar 4D).

MGE sangat melimpah dan berevolusi dengan cepat, sehingga sulit untuk mengidentifikasi secara sistematis batas-batas pasti elemen-elemen tersebut dalam konteks sekuens alaminya (Durrant et al., 2020). Menggunakan model yang telah di-fine-tune, kami menghitung entropi probabilitas bersyarat pada setiap posisi di seluruh lokus IS605 alami (Gambar 4E dan S8). Meskipun model dilatih tanpa pelabelan batas MGE secara eksplisit, sinyal entropi mengindikasikan bahwa model sedang mempelajari representasi batas-batas ini, dengan peningkatan entropi yang tajam dan berkelanjutan yang khususnya berhubungan dengan ujung 3' elemen. Secara keseluruhan, hasil-hasil ini menunjukkan bahwa model yang telah di-fine-tune dapat menghasilkan sistem IS605 yang beragam dengan sekuens protein dan RNA yang koheren, serta bahwa model tersebut mempelajari fitur-fitur penting dari elemen-elemen ini yang dapat dialihfungsikan untuk anotasi fungsional yang lebih baik.


2.7. Memprediksi esensialitas gen dengan konteks genomik panjang

Di luar tingkat molekuler atau sistem, kami merancang Evo agar mampu menganalisis genom utuh. Kami melakukan tahap kedua prapelatihan menggunakan model Evo yang telah dilatih pada 8k sebagai model dasar, melatihnya pada sekuens dengan 131k token (Gambar 5A) dengan token khusus tingkat spesies yang ditambahkan di depan. Tahap prapelatihan ini menggunakan data dari GTDB dan subset IMG/VR yang mengecualikan virus eukariotik (Gambar 1C dan S1). Lihat Metode untuk detail tambahan terkait perluasan konteks. Yang penting, Evo mempertahankan resolusi nukleotida tunggal pada ukuran konteks 131k, yang penting karena perubahan yang melibatkan sejumlah kecil pasangan basa masih dapat secara dramatis memengaruhi fenotipe seluruh organisme. Misalnya, bahkan mutasi nukleotida tunggal pada gen esensial dapat tidak kompatibel dengan kehidupan jika mutasi tersebut mengganggu ekspresi atau fungsi gen tersebut. Mengidentifikasi gen-gen esensial ini penting untuk memahami biologi fundamental suatu organisme dan untuk mengidentifikasi gen pada organisme patogenik yang dapat menjadi target obat penghambat (Rocha dan Dan chin, 2003).


Untuk tujuan ini, kami mengevaluasi kemampuan Evo dalam memprediksi esensialitas gen hanya berdasarkan mutasi pada genom sekuens. Kami melakukan percobaan di mana kami menyisipkan kodon stop prematur di awal setiap



Gambar 4 | Pelatihan lanjut pada sekuens IS200/IS605 memungkinkan desain generatif sistem biologis transposabel. (A) Sistem kelompok IS605 adalah sekelompok MGE yang termasuk dalam famili IS200/IS605 dan menyandikan transposase Y1-HuH yang disandi oleh sekuens penyandi TnpA serta kompleks TnpB-ωRNA yang melakukan pemotongan DNA. Tugas desain kami adalah menghasilkan sekuens yang mengandung komponen protein dan ncRNA ini. (B) Kami melakukan pelatihan lanjut pada Evo, setelah fase prap pelatihan awal 8k, pada sekuens sepanjang ~2 kb yang mengandung sistem IS200/IS605. (C) Histogram yang merepresentasikan distribusi persentase identitas lokus yang dihasilkan yang mengandung sekuens penyandi TnpA dan TnpB yang diprediksi. Anggota set pelatihan yang paling cocok menurut identifikasi MMseqs2 dibandingkan dengan sekuens yang dihasilkan melalui penyelarasan MAFFT. (D) Contoh elemen IS605 yang dihasilkan. Menampilkan struktur protein TnpA dan TnpB yang diprediksi oleh ESMFold (biru) diselaraskan dengan struktur PDB homolog (abu-abu) dan struktur sekunder ωRNA yang diprediksi. (E) Menampilkan entropi probabilitas bersyarat di setiap posisi pada tiga lokus IS605 alami. Sekuens penyandi TnpA (pendek) dan TnpB (panjang) ditampilkan dalam warna biru, batas ωRNA yang diprediksi ditampilkan dalam warna ungu, serta awal dan akhir elemen lengkap ditampilkan dengan batang hitam.



Gambar 5 | Evo melakukan prediksi esensialitas gen zero-shot pada berbagai genom bakteri dan fag. (A) Untuk tugas prediksi dan pembangkitan skala genom, kami terlebih dahulu melakukan prap pelatihan Evo pada sekuens dengan 8k token, kemudian memperluas ukuran jendela konteksnya dalam fase prap pelatihan kedua menjadi sekuens sepanjang 131k token. (B) Kami melakukan skrining mutagenesis in silico pada seluruh genom dengan memperkenalkan kodon stop prematur di setiap sekuens pengode dalam suatu genom. Kami menghitung likelihood model bahasa (LM) dari sekuens gen yang termutasi beserta sejumlah konteks genomik tambahan (hingga 66 kb). Kemudian, kami mengambil rasio likelihood ini terhadap likelihood sekuens yang tidak termutasi. Kami menguji apakah rasio likelihood ini dapat memprediksi esensialitas gen. (C) Plot violin dan strip distribusi kekuatan prediksi esensialitas gen di seluruh 58 studi (setiap titik mewakili studi yang berbeda), di mana setiap studi melakukan skrining esensialitas genom-lebar pada spesies bakteri ($N = 56$) atau fag ($N = 2$). Kami mengukur kinerja prediktif sebagai AUROC dengan menggunakan rasio likelihood LM untuk memprediksi label biner “esensial” atau “non-esensial”. “Konteks hanya gen” menunjukkan bahwa model hanya diberikan sekuens gen tanpa konteks genomik pengapit tambahan. “Konteks 8k” dan “Konteks 66k” menunjukkan bahwa LM diberikan sekuens gen dan konteks genomik pengapit hingga total masing-masing 8k atau 66k token. Evo memiliki kinerja prediktif yang terbatas dengan konteks hanya gen, mengalami peningkatan kinerja yang sangat besar dari konteks hanya gen ke konteks 8k, dan terdapat beberapa peningkatan pencilaan dari konteks 8k ke 66k. (D) Histogram yang merepresentasikan distribusi log dari rasio likelihood (“skor Evo”) untuk gen esensial (biru) dan gen non-esensial (kuning) pada dua genom: fag lambda (atas) dan *Pseudomonas aeruginosa* (bawah). Hasil ini didasarkan pada pemberian konteks 66k kepada Evo.



Gambar 6 | Evo menghasilkan sekuens skala-genom dengan arsitektur pengkodean yang padat. (A) Kami memberikan prompt pada Evo dengan token tingkat spesies yang digunakan selama tahap prapelatihan kedua. Kami menggunakan prompt spesies bakteri dan menghasilkan sekuens sepanjang ~650 kb. (B) Histogram yang menggambarkan distribusi skor kepadatan pengkodean di antara potongan sepanjang 131 kb dari sekuens yang dihasilkan oleh Evo ("hasil Evo"), sekuens dari bakteri alami ("genom alami"), atau sekuens yang empat pasangan basanya diambil sampel secara seragam acak ("sekuens acak"). (C) Plot panah yang menggambarkan organisasi sekuens pengkode pada contoh sekuens 131 kb yang dihasilkan oleh Evo, berasal dari genom alami, atau diambil sampel secara acak. Sekuens pengkode digambarkan sebagai panah dengan panjang horizontal panah sesuai dengan interval genomik dan arah panah menunjukkan untai. Baris panah atas dan bawah masing-masing menunjukkan untai 5'-ke-3' dan 3'-ke-5', dan sekuens yang dihasilkan Evo ditetapkan sebagai untai 5'-ke-3'. Baik genom hasil Evo maupun genom alami menunjukkan struktur mirip operon di mana kluster gen yang terlokasi bersama berada pada untai yang sama. (D, E) Contoh sekuens yang dihasilkan di representasikan sebagai plot panah seperti pada (C). Di bawah plot panah ini terdapat prediksi struktur ESMFold dari semua sekuens pengkode protein dengan panjang 100 hingga 1.024 asam amino yang diidentifikasi oleh Prodigal. Prediksi struktur disejajarkan dengan protein alami, yang kemudian dipetakan ke istilah fungsi molekuler GO terkait (Mende). Kategori GO terbesar ditampilkan sebagai kluster bersama dengan kluster besar yang berisi semua protein lainnya.

sekuens yang mewakili ~13 megabasa, Evo mengambil sampel 18 sekuens tRNA (dibandingkan dengan 35 tRNA pada ~580 kgenom b dari *M. genitalium*) dan tidak ada rRNA, sebagaimana dideteksi oleh program tRNAscan-SE (Chan dan Lowe, 2019) dan barnap (Seemann, 2018), masing-masing.

Hasil ini menunjukkan bahwa Evo dapat menghasilkan sekuens genom yang mengandung organisasi genomik tingkat tinggi yang masuk akal pada skala yang belum pernah terjadi sebelumnya tanpa rekayasa prompt yang ekstensif atau penyetulan lanjut. Sampel-sampel ini mewakili sebuah “gambar buram” dari suatu genom yang mengandung karakteristik kunci tetapi tidak memiliki detail yang lebih halus yang khas dari genom alami. Hal ini konsisten dengan temuan yang melibatkan model generatif di domain lain, seperti bahasa alami atau pembangkitan gambar. Sebagai contoh, pengambilan sampel secara langsung dari model bahasa alami yang besar biasanya menghasilkan urutan yang secara tata bahasa benar, namun secara lokal bias terhadap konstruksi kalimat yang lebih sederhana, dan secara global tidak koheren, terutama pada panjang yang besar. Menjanjikan, di domain-domain ini, teknik-teknik algoritmik telah muncul untuk meningkatkan kualitas hasil generasi dibandingkan dengan pengambilan sampel dari model pra-latih saja (Wei et al., 2022; Ouyang et al., 2022; Rafailov et al., 2024). Kualitas generasi dasar yang diamati pada Evo pra-latih menunjukkan bahwa Evo juga dapat diadaptasi untuk teknik-teknik ini.

3. Pembahasan

Evo adalah model fondasi genomik yang dilatih pada ratusan miliar token DNA di seluruh keanekaragaman evolusioner kehidupan prokariotik, mampu melakukan tugas prediksi dan generasi pada skala molekul individual, kompleks molekuler, sistem biologis, dan bahkan seluruh genom. Berdasarkan arsitektur model hibrida mutakhir, StripedHyena, Evo memungkinkan pemodelan bahasa resolusi nukleotida tunggal pada panjang konteks 131k. Kami melakukan analisis hukum penskalaan pertama terhadap praplatihan DNA pada beberapa arsitektur, di mana kami mengamati StripedHyena mengungguli beberapa arsitektur dasar, termasuk arsitektur Transformer, pada setiap tingkat skala. Evo secara akurat melakukan prediksi zero-shot pada beragam tugas prediksi kebugaran atau ekspresi pada protein, ncRNA, atau DNA regulatori yang menyamai atau melampaui model-model khusus, sekaligus memahami gen mana yang esensial bagi kebugaran organisme. Evo juga merupakan model generatif, yang kami manfaatkan untuk mengambil sampel protein CRISPR-Cas dan RNA pandu nonkodingnya, sistem transposabel multigen, serta sekuens ~650 kb yang mereka titulasi organisasi pengkodean genom nyata. Kami menyediakan kode dan model sumber terbuka untuk Evo secara publik di <https://github.com/evo-design/evo>.

Model yang mampu melakukan desain skala genom memiliki potensi besar untuk memajukan penemuan terapeutik, keberlanjutan, dan pemahaman kita tentang biologi fundamental, tetapi secara bersamaan menimbulkan pertimbangan biosekuriti dan etika. The Global Alliance for Genomics and Health (GA4GH) (Rehm et al., 2021) telah mengembangkan prinsip-prinsip untuk pengawasan teknologi rekayasa genetika dan dapat menyediakan dasar yang kokoh untuk transparansi, akuntabilitas, dan tanggung jawab bersama. Kerangka kerja semacam itu penting untuk mendorong kerja sama internasional yang bermanfaat bagi seluruh umat manusia. Diskusi proaktif yang melibatkan komunitas ilmiah, pakar keamanan, dan pembuat kebijakan sangat penting untuk mencegah penyalahgunaan dan mempromosikan strategi yang efektif untuk memitigasi ancaman yang ada dan yang baru muncul. Lebih jauh lagi, investasi dalam pendidikan dan pengembangan kapasitas, terutama di komunitas yang kekurangan sumber daya, akan secara berkelanjutan mendemokratisasi akses dan penggunaan alat seperti Evo. Kami membuka sumber model ini untuk mendorong transparansi dan memulai dialog dengan komunitas ilmiah yang lebih luas dan para pemangku kepentingan. Kami juga menerapkan kehati-hatian dengan mengecualikan virus eukariotik dari dataset pra-pelatihan kami. Kami menyertakan pembahasan yang lebih luas tentang pertimbangan etika dalam suplemen pembahasan Keamanan dan etika di mana kami menilai risiko alat seperti Evo, termasuk potensinya untuk disalahgunakan, berkontribusi pada ketidaksetaraan sosial dan kesehatan, atau mengganggu lingkungan alam. Pedoman yang jelas dan komprehensif yang menggambarkan praktik etika untuk bidang ini diperlukan untuk pengembangan dan penggunaan model bahasa skala genom yang bertanggung jawab.

Meskipun memiliki kemampuan luar biasa, model fondasi DNA generasi pertama ini masih memiliki sejumlah keterbatasan dan tantangan teknis. Kami melakukan praplatihan Evo pada set data berisi 300 miliar token prokariotik, yang hanya mewakili sebagian sangat kecil dari data genomik publik berskala petabita. Karena model kami hanya dilatih pada data prokariotik, kemampuan kami untuk memprediksi efek fungsional mutasi pada kebugaran protein manusia menjadi terbatas. Model bahasa alami sering kali kesulitan mempertahankan generasi yang koheren dan beragam pada sekuens panjang, dan Evo dapat menunjukkan sifat yang serupa. Sebagai contoh, kami mengamati bahwa sekuens CRISPR-Cas yang lebih baru disampel pada frekuensi yang relatif rendah dan pemberian prompt pada token khusus memiliki tingkat keterkendalian yang sedang, kadang-kadang menghasilkan protein Cas9 ketika diberi prompt dengan token Cas12. Pada skala genom, Evo menghasilkan ratusan kilobasa yang menunjukkan pemahaman tingkat tinggi tentang organisasi genom, tetapi kesulitan untuk menyertakan gen penanda kunci seperti repertoar tRNA pengode lengkap. Keterbatasan ini mencerminkan kendala model bahasa alami, yang telah ditingkatkan seiring waktu melalui peningkatan skala, data berlabel, prompt

erekayasa, dan penyelarasan dengan preferensi manusia (Kaplan et al., 2020; Ouyang et al., 2022; Wei et al., 2022; Kojima et al., 2022; Rafailov et al., 2024). Kami memperkirakan lintasan yang serupa untuk model DNA.

Pemodelan DNA pada skala dan resolusi ini meletakkan dasar bagi beragam arah penelitian. Kami memperkirakan bahwa Evo akan memperoleh manfaat dari skala tambahan, panjang konteks yang lebih besar, dan data prapelatihan yang lebih beragam. Mengingat keberhasilan evolusi terarah protein yang dipandu oleh model bahasa (Hie et al., 2024), model bahasa genomik juga dapat membantu memandu evolusi terarah sistem biologis multigen. Demikian pula, informasi ko-evolusi yang terkandung dalam model-model ini dapat meningkatkan prediksi struktur molekuler dalam konteks multigen (Jumper et al., 2021; Lin et al., 2023). Sifat-sifat biologi sistem dapat muncul seiring dengan peningkatan model ini, seperti efek kebugaran dari interaksi gen kombinatorial atau prediksi keterkaitan operon fungsional. Dengan pengkondisian atau rekayasa prompt yang lebih baik, Evo dapat menjadi dasar algoritma pencarian sekuens generasi berikutnya dengan memungkinkan penambangan metagenomik pada tingkat relasional atau semantik, alih-alih mengekstraksi sekuens literal dari organisme yang ada. Di luar prokariota, penggabungan genom eukariotik ke dalam Evo perlu mempertimbangkan kompleksitas genom ini yang jauh lebih tinggi dan memerlukan investasi sumber daya yang substansial dalam rekayasa, komputasi, dan penyelarasan model terkait keamanan. Dikombinasikan dengan kemajuan dalam modifikasi genom skala besar (Durrant et al., 2024), Evo membantu memperluas cakupan rekayasa dan desain biologi ke skala seluruh genom.

4. Ketersediaan kode dan data

Kode dan model yang terkait dengan studi ini tersedia secara publik di <https://github.com/evo-design/evo>.

Kami menggunakan dataset berikut untuk prapelanahan:

- Genom bakteri dan arkea dari Genome Taxonomy Database (GTDB) v214.1 (Parks et al., 2015).
- Virus prokariotik terkurasi dari database IMG/VR v4 (Camargo et al., 2023).
- Sekuen plasmid dari basis data IMG/PR (Camargo et al., 2024).

Selain dataset di atas, kami juga menggunakan sebagian dari dataset berikut untuk finetuning:

- NCBI RefSeq (O'Leary et al., 2016).
- UHGG (Almeida et al., 2021).
- JGI IMG (Chen et al., 2021).
- Basis Data Fag Usus (Camarillo-Guerrero et al., 2021).
- Koleksi Genom Bakteri Gastrointestinal Manusia (Forster et al., 2019).
- MGnify (Mitchell et al., 2020).
- Youngblut et al. (2020) metagenom usus hewan.
- MGRAST (Meyer et al., 2008).
- Sampel Tara Oceans (Sunagawa et al., 2015).

Informasi lebih lanjut mengenai dataset ini disediakan di Metode.

5. Ucapan Terima Kasih

Kami mengucapkan terima kasih kepada Elijah Chanakira, Dave Driggers, Richard Dugan, Helmut Fritz, Marco Iskender, Adeesh Jain, Mike LaPan, Sean Marrs, Sigalit Perelson, Randy Rizun, Jason Rojas, dan Delaney Ugelstad atas bantuan infrastruktur komputasi. Kami mengucapkan terima kasih kepada Samuel Sternberg dan Chance Meers atas penyediaan model kovarians untuk mengidentifikasi beragam ω RNAs. Kami mengucapkan terima kasih kepada Jessica Adkins, Joana Carvalho, Dan Fu, Jared Dunnmon, Yunha Hwang, Julia Kazaks, Gautam Machiraju, April Pawluk, Christina Theodoris, Ben Viggiano, dan Alden Woodrow atas diskusi yang bermanfaat dan bantuan dalam penyusunan naskah. P.D.H. mengucapkan terima kasih atas dukungan pendanaan dari Arc Institute, Rainwater Foundation, Curci Foundation, Rose Hill Innovators Program, V. dan N. Khosla, S. Altman, serta donasi anonim untuk Hsu Lab. B.L.H. mengucapkan terima kasih atas dukungan pendanaan dari Arc Institute, Varun Gupta, dan Raymond Tonsing.

6. Kontribusi Penulis

E.N., P.D.H., dan B.L.H. menggagas proyek ini. P.D.H. dan B.L.H. mengawasi proyek ini. E.N., M.P., dan A.W.T. merancang arsitektur model. M.G.D. dan B.L.H. mengkurasi dan memproses dataset pelatihan awal dan penyetelan halus. M.P. mengimplementasikan infrastruktur pelatihan dan pembangkitan yang dioptimalkan. E.N., A.W.T., dan B.L.H. berkontribusi pada infrastruktur pelatihan dan pembangkitan yang dioptimalkan. E.N., M.P., dan A.W.T. mengimplementasikan dan melaksanakan analisis hukum skala. E.N., M.P., A.W.T., dan B.L.H. mengevaluasi model yang telah dilatih awal. E.N. dan B.L.H. melakukan penyetelan halus model. B.K. dan P.D.H. mengambil sampel atau menganalisis generasi CRISPR-Cas. M.G.D. dan B.L.H. mengambil sampel atau menganalisis generasi IS200/IS605. B.L.H. melakukan analisis esensialitas gen. M.P. dan B.L.H. melakukan pengambilan sampel dan analisis skala genom. M.P., A.W.T., dan B.L.H. mengimplementasikan basis kode Evo publik. M.Y.N., A.L., dan T.H-B. melakukan investigasi dan diskusi etika dan keamanan. E.N., M.P., M.G.D., P.D.H., dan B.L.H. menulis draf pertama manuskrip. Seluruh penulis menulis draf akhir manuskrip.

7. Konflik Kepentingan

M.P. adalah karyawan TogetherAI. M.G.D. mengakui adanya kepentingan di luar pada Stylus Medicine. C.R. mengakui kepentingan eksternal di Factory dan Google Ventures. P.D.H. mengakui kepentingan eksternal di Stylus Medicine,

Spotlight Therapeutics, Circle Labs, Arbor Biosciences, Varda Space, Vial Health, dan Veda Bio, di mana ia memegang berbagai peran termasuk sebagai salah satu pendiri, direktur, anggota dewan penasihat ilmiah, atau konsultan. B.L. H. menyatakan memiliki kepentingan di luar di Prox Biosciences sebagai salah satu pendiri ilmiah. Semua penulis lain menyatakan tidak memiliki konflik kepentingan.

Daftar Pustaka

- B. Adkar, A. Tripathi, A. Sahoo, K. Bajaj, D. Goswami, P. Chakrabarti, M. Swarnkar, R. Gokhale, dan R. Varadarajan. Diskriminasi model protein menggunakan sensitivitas mutasi yang diperoleh dari sekuensing mendalam. *Structure*, 20:371–381, 2 2012. ISSN 09692126. doi: 10.1016/j.str.2011.11.021.
- J. Ainslie, J. Lee-Thorp, M. de Jong, Y. Zemlyanskiy, F. Lebrón, dan S. Sanghai. Gqa: Pelatihan model transformer multi-kueri tergeneralisasi dari checkpoint multi-kepala. *arXiv preprint arXiv:2305.13245*, 2023.
- A. Almeida, S. Nayfach, M. Boland, F. Strozzi, M. Beracochea, Z. J. Shi, K. S. Pollard, E. Sakharova, D. H. Parks, P. Hugenholtz, N. Segata, N. C. Kyrpides, dan R. D. Finn. Katalog terpadu 204.938 genom referensi dari mikrobioma usus manusia. *Nat. Biotechnol.*, 39(1):105–114, Jan. 2021.
- H. Altae-Tran, S. Kannan, F. E. Demircioglu, R. Oshiro, S. P. Nety, L. J. McKay, M. Dlakić, W. P. Inskeep, K. S. Makarova, R. K. Macrae, E. V. Koonin, dan F. Zhang. Famili transposon IS200/IS605 yang tersebar luas menyandikan berbagai endonuklease terpadu RNA yang dapat diprogram. *Science*, 374:57–65, 10 2021. ISSN 0036-8075. doi: 10.1126/science.abj6856.
- H. Altae-Tran, S. A. Shmakov, K. S. Makarova, Y. I. Wolf, S. Kannan, F. Zhang, and E. V. Koonin. Keanekaragaman, evolusi, dan klasifikasi nuklease berpandu RNA TnpB dan cas12. *Proc. Natl. Acad. Sci. U. S. A.*, 120(48):e2308224120, Nov. 2023.
- J. O. L. Andreasson, A. Savinov, S. M. Block, dan W. J. Greenleaf. Pemetaan komprehensif sekuens-ke-fungsi katalis is RNA yang bergantung pada kofaktor pada ribozim glms. *Nat. Commun.*, 11(1):1663, Apr. 2020.
- S. Arora, S. Eyuboglu, A. Timalisina, I. Johnson, M. Poli, J. Zou, A. Rudra, and C. Ré. Zoologi: Mengukur dan meningkatkan recall pada model bahasa efisien. *arXiv preprint arXiv:2312.04927*, 2023.
- Z. Avsec, V. Agarwal, D. Visentin, J. R. Ledsam, A. Grabska-Barwinska, K. R. Taylor, Y. Assael, J. Jumper, P. Kohli, and D. R. Kelley. Prediksi ekspresi gen yang efektif dari sekuens dengan mengintegrasikan interaksi jarak jauh. *Nature Methods*, 18:1196–1203, 10 2021. ISSN 1548-7091. doi: 10.1038/s41592-021-01252-x.
- K. Badal, C. M. Lee, dan L. J. Esserman. Prinsip panduan untuk pengembangan alat kecerdasan buatan yang bertanggung jawab untuk perawatan kesehatan. *Communications Medicine*, 3:47, 4 2023. ISSN 2730-664X. doi: 10.1038/s43856-023-00279-9.
- D. Baker dan G. Church. Desain Protein Bertemu Biosekuriti. *Science*, 383(6681):349–349, 2024. G. Benegas, C. Albers, A. J. Aw, C. Ye, dan Y. S. Song. GPN-MSA: model bahasa DNA berbasis penjajaran untuk prediksi efek varian di seluruh genom. *bioRxiv*, halaman 2023.10.10.561776, 1 2023. doi: 10.1101/2023.10.10.561776. URL <http://biorxiv.org/content/early/2023/10/11/2023.10.10.561776.abstract>.
- S. Bhattamishra, A. Patel, P. Blunsom, dan V. Kanade. Memahami pembelajaran dalam konteks pada transformer dan LLM dengan belajar mempelajari fungsi diskret. *arXiv preprint arXiv:2310.03016*, 2023.
- A. Blanchard dan C. Bébér. Evolusi *Mycoplasma genitalium*. *Annals of the New York Academy of Sciences*, 1230, 8 2011. ISSN 0077-8923. doi: 10.1111/j.1749-6632.2011.06418.x.
- C. Bland, T. L. Ramsey, F. Sabree, M. Lowe, K. Brown, N. C. Kyrpides, dan P. Hugenholtz. CRISPR recognition tool (CRT): sebuah alat untuk deteksi otomatis clustered regularly interspaced palindromic repeats. *BMC Bioinformatics*, 8:209, Juni 2007.
- A. P. Camargo, S. Nayfach, I.-M. A. Chen, K. Palaniappan, A. Ratner, K. Chu, S. Ritter, T. B. K. Reddy, S. Mukherjee, F. Schulz, L. Call, R. Neches, T. Woyke, N. Ivanova, E. Elie-Fadrosh, N. Kyrpides, dan S. Roux. IMG/VR v4: basis data yang diperluas dari genom virus yang tidak dikultur dalam kerangka metadata fungsional, taksonomi, dan ekologi yang ekstensif. *Nucleic Acids Research*, 51:D733–D743, 1 2023. ISSN 0305-1048. doi: 10.1093/nar/gkac1037.

- A. P. Camargo, L. Call, S. Roux, S. Nayfach, M. Huntemann, K. Palaniappan, A. Ratner, K. Chu, S. Mukherjee, T. B. K. Reddy, I.-M. Chen, N. Ivanova, E. Elie-Fadrosh, T. Woyke, D. Baltrus, S. Castañeda-Barba, F. de la Cruz, B. E. Funnell, J. J. Hall, A. Mukhopadhyay, E. C. Rocha, T. Stalder, E. Top, dan N. Kyrpides. IMG/PR: Basis data plasmid dari genom dan metagenom dengan anotasi dan metadata yang kaya. *Nucleic Acids Research*, 52:D164–D173, 1 2024. ISSN 0305-1048. doi: 10.1093/nar/gkad964.
- L. F. Camarillo-Guerrero, A. Almeida, G. Rangel-Pineros, R. D. Finn, dan T. D. Lawley. Ekspansi masif keragaman bakteriofag usus manusia. *Cell*, 184(4):1098–1109.e9, Feb. 2021.
- P. P. Chan dan T. M. Lowe. *tRNAscan-SE: Searching for tRNA Genes in Genomic Sequences*, halaman 1–14. 2019. doi: 10.1007/978-1-4939-9173-0_1.
- M. Chandler, M. Gellert, A. M. Lambowitz, P. A. Rice, dan S. B. Sandmeyer. *Mobile DNA III*. John Wiley & Sons, Juli 2020.
- T. A. Chang dan B. K. Bergen. Perilaku model bahasa: Sebuah survei komprehensif. Mar. 2023.
- I.-M. A. Chen, K. Chu, K. Palaniappan, A. Ratner, J. Huang, M. Huntemann, P. Hajek, S. Ritter, N. Varghese, R. Sesadri, S. Roux, T. Woyke, E. A. Elie-Fadrosh, N. N. Ivanova, and N. C. Kyrpides. Sistem manajemen dan analisis data IMG/M v.6.0: perangkat baru dan kemampuan canggih. *Nucleic Acids Res.*, 49(D1): D751–D763, Jan. 2021.
- J. Chen, Z. Hu, S. Sun, Q. Tan, Y. Wang, Q. Yu, L. Zong, L. Hong, J. Xiao, T. Shen, I. King, dan Y. Li. Model dasar RNA yang dapat diinterpretasi dari data tidak beranotasi untuk prediksi struktur dan fungsi RNA yang sangat akurat, 2022.
- S. Chen, S. Wong, L. Chen, and Y. Tian. Memperluas jendela konteks model bahasa besar melalui interpolasi posisional. *arXiv preprint arXiv:2306.15595*, 2023.
- H. Dalla-Torre, L. Gonzalez, J. Mendoza-Revilla, N. L. Carranza, A. H. Grzywaczewski, F. Oteri, C. Dallago, E. Tropea, B. P. de Almeida, H. Sirelkhatim, G. Richard, M. Skwark, K. Beguir, M. Lopez, and T. Pierrot. The Nucleotide Transformer: Membangun dan Mengevaluasi Model Fondasi yang Kokoh untuk Genomika Manusia. *bioRxiv*, page 2023.01.11.523679, 1 2023. doi: 10.1101/2023.01.11.523679. URL <http://biorxiv.org/content/early/2023/09/19/2023.01.11.523679.abstract>.
- L. F. DaSilva, S. Senan, Z. M. Patel, A. J. Reddy, S. Gabbita, Z. Nussbaum, C. M. V. Córdova, A. Wenteler, N. Weber, T. M. Tunjic, T. A. Khan, Z. Li, C. Smith, M. Bejan, L. K. Louis, P. Cornejo, W. Connell, E. S. Wong, W. Meuleman, dan L. Pinello. Dna-diffusion: Memanfaatkan model generatif untuk mengendalikan aksesibilitas kromatin dan ekspresi gen melalui elemen regulatorik sintetis. *bioRxiv*, halaman 2024.02.01.578352, 1 2024. doi: 10.1101/2024.02.01.578352. URL <http://biorxiv.org/content/early/2024/02/01/2024.02.01.578352.abstract>.
- Y. N. Dauphin, A. Fan, M. Auli, dan D. Grangier. Language modeling with gated convolutional networks. Dalam *International conference on machine learning*, halaman 933–941. PMLR, 2017.
- T. Dobzhansky. *Genetics and the Origin of Species*. Columbia University Press, 1951.
- J. Domingo, G. Diss, dan B. Lehner. Interaksi genetik berpasangan dan tingkat tinggi selama evolusi suatu tRNA. *Nature*, 558(7708):117–121, Juni 2018.
- M. G. Durrant, M. M. Li, B. A. Siranosian, S. B. Montgomery, dan A. S. Bhatt. Analisis bioinformatika elemen genetik bergerak integratif menyoroti perannya dalam adaptasi bakteri. *Cell Host & Microbe*, 27: 140–153.e9, 1 2020. ISSN 1931-3128. doi: 10.1016/j.chom.2019.10.022.
- M. G. Durrant, N. T. Perry, J. J. Pai, A. R. Jangid, J. S. Athukoralage, M. Hiraizumi, J. P. McSpedon, A. Pawluk, H. Nishimasu, S. Konermann, dan P. D. Hsu. RNA jembatan mengarahkan rekombinasi modular dan terprogram dari DNA target dan donor. *bioRxiv*, halaman 2024.01.24.577089, 1 2024. doi: 10.1101/2024.01.24.577089. URL <http://biorxiv.org/content/early/2024/01/26/2024.01.24.577089.abstract>.
- G. M. Findlay, R. M. Daza, B. Martin, M. D. Zhang, A. P. Leith, M. Gasperini, J. D. Janizek, X. Huang, L. M. Starita, dan J. Shendure. Klasifikasi akurat varian brca1 dengan penyuntingan genom saturasi. *Nature*, 562:217–222, 10 2018. ISSN 0028-0836. doi: 10.1038/s41586-018-0461-z.

R. D. Finn, J. Clements, dan S. R. Eddy. Server web HMMER: pencarian kemiripan sekuens interaktif. *Nucleic Acids Res.*, 39(Edition Server Web):W29–37, Juli 2011.

E. Firnberg, J. W. Labonte, J. J. Gray, and M. Ostermeier. Peta lanskap kebugaran gen yang komprehensif dan beresolusi tinggi. *Molecular Biology and Evolution*, 31:1581–1592, 6 2014. ISSN 1537-1719. doi: 10.1093/molbev/msu081.

V. Fishman, Y. Kuratov, M. Petrov, A. Shmelev, D. Shepelin, N. Chekanov, O. Kardymon, dan M. Burtsev. GENE-LM: Sebuah keluarga model bahasa DNA dasar sumber terbuka untuk sekuens panjang. *bioRxiv*, halaman 2023.06.12.544594, 1 2023. doi: 10.1101/2023.06.12.544594. URL <http://biorxiv.org/content/early/2023/11/01/2023.06.12.544594.abstract>.

S. C. Forster, N. Kumar, B. O. Anonye, A. Almeida, E. Viciani, M. D. Stares, M. Dunn, T. T. Mkandawire, A. Zhu, Y. Shao, L. J. Pike, T. Louie, H. P. Browne, A. L. Mitchell, B. A. Neville, R. D. Finn, and T. D. Lawley. Koleksi genom dan kultur bakteri usus manusia untuk analisis metagenomik yang lebih baik. *Nat. Biotechnol.*, 37(2): 186–192, Feb. 2019.

D. Fu, S. Arora, J. Grogan, I. Johnson, E. S. Eyuboglu, A. Thomas, B. Spector, M. Poli, A. Rudra, dan C. Ré. Monarch mixer: Arsitektur berbasis GEMM sub-kuadratik sederhana. *Advances in Neural Information Processing Systems*, 36, 2024.

D. Y. Fu, T. Dao, K. K. Saab, A. W. Thomas, A. Rudra, dan C. Ré. Kuda nil lapar-lapar: Menuju pemodelan bahasa dengan model ruang keadaan. *arXiv preprint arXiv:2212.14052*, 2022.

C. W. Garvie, X. Wu, M. Papanastasiou, S. Lee, J. Fuller, G. R. Schnitzler, S. W. Horner, A. Baker, T. Zhang, J. P. Mullahoo, L. Westlake, S. H. Hoyt, M. Toetzel, M. J. Ranaghan, L. de Waal, J. McGaunn, B. Kaplan, F. Piccioni, X. Yang, M. Lange, A. Tersteegen, D. Raymond, T. A. Lewis, S. A. Carr, A. D. Cherniack, C. T. Lemke, M. Meyerson, dan H. Greulich. Struktur kompleks PDE3A-SLFN12 mengungkap persyaratan untuk aktivasi RNase SLFN12. *Nature Communications*, 12:4375, 7 2021. ISSN 2041-1723. doi: 10.1038/s41467-021-24495-w.

G. Gasiunas, J. K. Young, T. Karvelis, D. Kazlauskas, T. Urbaitis, M. Jasnauskaite, M. M. Grusyte, S. Paulraj, P.-H. Wang, Z. Hou, S. K. Dooley, M. Cigan, C. Alarcon, N. D. Chilcoat, G. Bigelyte, J. L. Curcuru, M. Mabuchi, Z. Sun, R. T. Fuchs, E. Schildkraut, P. R. Weigele, W. E. Jack, G. B. Robb, Česlovas Venclovas, dan V. Siksnys. Katalog ortolog CRISPR-Cas9 yang beragam secara biokimia. *Nature Communications*, 11:5512, 11 2020. ISSN 2041-1723. doi: 10.1038/s41467-020-19344-1.

A. O. Giacomelli, X. Yang, R. E. Lintner, J. M. McFarland, M. Duby, J. Kim, T. P. Howard, D. Y. Takeda, S. H. Ly, E. Kim, H. S. Gannon, B. Hurhula, T. Sharpe, A. Goodale, B. Fritchman, S. Steelman, F. Vazquez, A. Tsherniak, A. J. Aguirre, J. G. Doench, F. Piccioni, C. W. M. Roberts, M. Meyerson, G. Getz, C. M. Johannessen, D. E. Root, and W. C. Hahn. Proses mutasional membentuk lanskap mutasi tp53 pada kanker manusia. *Nature Genetics*, 50:1381–1387, 10 2018. ISSN 1061-4036. doi: 10.1038/s41588-018-0204-y.

A. R. Gruber, R. Lorenz, S. H. Bernhart, R. Neuböck, dan I. L. Hofacker. Suite Web RNA Vienna. *Nucleic Acids Res.*, 36(Edition Server Web):W70–4, Juli 2008.

A. Gu dan T. Dao. Mamba: Pemodelan sekuens waktu-linear dengan ruang keadaan selektif. *arXiv preprint arXiv:2312.00752*, 2023.

A. Gu, K. Goel, dan C. Ré. Pemodelan sekuens panjang secara efisien dengan ruang keadaan terstruktur. *arXiv preprint arXiv:2111.00396*, 2021.

A. Gu, K. Goel, A. Gupta, dan C. Ré. Mengenai parameterisasi dan inisialisasi model ruang keadaan diagonal. *Advances in Neural Information Processing Systems*, 35:35971–35983, 2022.

A. Gupta, A. Gu, dan J. Berant. Ruang keadaan diagonal sama efektifnya dengan ruang keadaan terstruktur. *Advances in Neural Information Processing Systems*, 35:22982–22994, 2022.

M. P. Guy, D. L. Young, M. J. Payea, X. Zhang, Y. Kon, K. M. Dean, E. J. Grayhack, D. H. Mathews, S. Fields, dan E. M. Phizicky. Identifikasi determinan fungsi tRNA dan kerentanan terhadap peluruhan tRNA cepat melalui analisis in vivo throughput tinggi. *Genes Dev.*, 28(15):1721–1732, Agu. 2014.

E. J. Hayden, E. Ferrada, dan A. Wagner. Variasi genetik kriptik mendorong adaptasi evolusioner yang cepat pada enzim RNA. *Nature*, 474(7349):92–95, Juni 2011.

B. L. Hie, V. R. Shanker, D. Xu, T. U. J. Bruun, P. A. Weidenbacher, S. Tang, W. Wu, J. E. Pak, dan P. S. Kim. Evolusi efisien antibodi manusia dari model bahasa protein umum. *Nature Biotechnology*, 42: 275–283, 2 2024. ISSN 1087-0156. doi: 10.1038/s41587-023-01763-2.

J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. d. L. Casas, L. A. Hendricks, J. Welbl, A. Clark, dkk. Pelatihan model bahasa besar yang optimal secara komputasi. *arXiv preprint arXiv:2203.15556*, 2022.

P. D. Hsu, E. S. Lander, dan F. Zhang. Pengembangan dan aplikasi CRISPR-Cas9 untuk rekayasa genom. *Cell*, 157:1262–1278, 6 2014. ISSN 00928674. doi: 10.1016/j.cell.2014.05.010.

Y. Hwang, A. L. Cornman, E. H. Kellogg, S. Ovchinnikov, dan P. R. Girguis. Model bahasa genomik memprediksi ko-regulasi dan fungsi protein. *bioRxiv*, 2023. doi: 10.1101/2023.04.07.536042. URL <https://www.biorxiv.org/content/early/2023/10/15/2023.04.07.536042>.

D. Hyatt, G.-L. Chen, P. F. LoCascio, M. L. Land, F. W. Larimer, dan L. J. Hauser. Prodigal: pengenalan gen prokariotik dan identifikasi situs inisiasi translasi. *BMC Bioinformatics*, 11:119, 12 2010. ISSN 1471-2105. doi: 10.1186/1471-2105-11-119.

J. B. Ingraham, M. Baranov, Z. Costello, K. W. Barber, W. Wang, A. Ismail, V. Frappier, D. M. Lord, C. Ng-Thow-Hing, E. R. V. Vlack, S. Tie, V. Xue, S. C. Cowles, A. Leung, J. V. Rodrigues, C. L. Morales-Perez, A. M. Ayoub, R. Green, K. Puentes, F. Oplinger, N. V. Panwar, F. Obermeyer, A. R. Root, A. L. Beam, F. J. Poelwijk, and G. Grigoryan. Menerangi ruang protein dengan model generatif yang dapat diprogram. *Nature*, 623:1070–1078, 11 2023. ISSN 0028-0836. doi: 10.1038/s41586-023-06728-8.

H. Jacquier, A. Birgy, H. L. Nagard, Y. Mechulam, E. Schmitt, J. Glodt, B. Bercot, E. Petit, J. Poulain, G. Barnaud, P. A. Gros, dan O. Tenaillon. Menangkap lanskap mutasi beta-laktamase TEM-1. *Proceedings of the National Academy of Sciences*, 110:13067–13072, Agustus 2013. ISSN 0027-8424. doi: 10.1073/pnas.1215206110.

Y. Ji, Z. Zhou, H. Liu, dan R. V. Davuluri. DNABERT: model representasi enkoder bidirectional pra-terlatih dari transformer untuk bahasa-DNA dalam genom. *Bioinformatics*, 37:2112–2120, 8 Agustus 2021. ISSN 1367-4803. doi: 10.1093/bioinformatics/btab083.

J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Åk, A. Potapenko, A. Bridgland, C. Meyer, S. A. A. Kohl, A. J. Ballard, A. Cowie, B. Romera-Paredes, S. Nikolov, R. Jain, J. Adler, T. Back, S. Petersen, D. Reiman, E. Clancy, M. Zielinski, M. Steinegger, M. Pacholska, T. Berghammer, S. Bodenstein, D. Silver, O. Vinyals, A. W. Senior, K. Kavukcuoglu, P. Kohli, and D. Hassabis. Prediksi struktur protein yang sangat akurat dengan AlphaFold. *Nature*, 596:583–589, 8 2021. ISSN 0028-0836. doi: 10.1038/s41586-021-03819-2.

J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, dan D. Amodei. Hukum skala untuk model bahasa neural. *arXiv preprint arXiv:2001.08361*, 2020.

T. Karvelis, G. Druteika, G. Bigelyte, K. Budre, R. Zedaveinyte, A. Silanskas, D. Kazlauskas, A. Česlovas Venclovas, dan V. Siksnys. TnpB yang terkait transposon adalah endonuklease DNA terpandu RNA yang dapat diprogram. *Nature*, 599:692–696, 11 2021. ISSN 0028-0836. doi: 10.1038/s41586-021-04058-1.

K. Katoh, K. Misawa, K.-I. Kuma, dan T. Miyata. MAFFT: metode baru untuk penyelarannya sekuens berganda cepat berdasarkan transformasi Fourier cepat. *Nucleic Acids Res.*, 30(14):3059–3066, Juli 2002.

E. D. Kelsic, H. Chung, N. Cohen, J. Park, H. H. Wang, and R. Kishony. Determinan struktural RNA dari kodon optimal diungkapkan oleh MAGE-Seq. *Cell Systems*, 3:563–571.e6, 12 2016. ISSN 24054712. doi: 10.1016/j.cels.2016.11.004.

S. Kobori, Y. Nomura, A. Miu, dan Y. Yokobayashi. Uji high-throughput dan rekayasa ribozim swa-potong melalui sekuensing. *Nucleic Acids Res.*, 43(13):e85, Juli 2015.

T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, dan Y. Iwasawa. Model bahasa besar adalah penalar zero-shot. *Advances in Neural Information Processing Systems*, 35:22199–22213, 2022.

E. V. Koonin dan K. S. Makarova. Asal-usul dan evolusi sistem CRISPR-Cas. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 374:20180087, 5 2019. ISSN 0962-8436. doi: 10.1098/rstb.2018.0087.

S. Kosuri, D. B. Goodman, G. Cambray, V. K. Mutalik, Y. Gao, A. P. Arkin, D. Endy, dan G. M. Church. Komposisi sekuens regulatorik yang mengontrol transkripsi dan translasi pada *Escherichia coli*. *Proceedings of the National Academy of Sciences*, 110:14024–14029, 8 2013. ISSN 0027-8424. doi: 10.1073/pnas.1301301110.

E. Kotler, O. Shani, G. Goldfeld, M. Lotan-Pompan, O. Tarcic, A. Gershoni, T. A. Hopf, D. S. Marks, M. Oren, dan E. Segal. Pustaka mutasi p53 yang sistematis menghubungkan dampak fungsional diferensial dengan pola mutasi kan ker dan konservasi evolusioner. *Molecular Cell*, 71:178–190.e8, 7 2018. ISSN 10972765. doi: 10.1016/j.molcel.2018.06.012.

A. Lal, D. Garfield, T. Biancalani, dan G. Eraslan. reglm: Merancang DNA regulatoris realistis dengan model bahasa autoregresif. *bioRxiv*, halaman 2024.02.14.580373, 1 2024. doi: 10.1101/2024.02.14.580373. URL <http://biorxiv.org/content/early/2024/02/19/2024.02.14.580373.abstract>.

W. B. Langdon, J. Petke, dan R. Lorenz. Evolusi prediksi struktur RNAfold yang lebih baik. Dalam *Genetic Programming*, halaman 220–236. Springer International Publishing, 2018.

F.-Z. Li, A. P. Amini, Y. Yue, K. K. Yang, dan A. X. Lu. Penggunaan Kembali Fitur dan Penskalaan: Memahami Pembelajaran Transfer dengan Model Bahasa Protein. *bioRxiv*, halaman 2024.02.05.578959, 1 2024. doi: 10.1101/2024.02.05.578959. URL <http://biorxiv.org/content/early/2024/02/14/2024.02.05.578959.abstract>.

Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart, dan A. Anandkumar. Operator neural Fourier untuk persamaan diferensial parsial parametrik. *arXiv preprint arXiv:2010.08895*, 2020.

Z. Lin, H. Akin, R. Rao, B. Hie, Z. Zhu, W. Lu, N. Smetanin, R. Verkuil, O. Kabeli, Y. Shmueli, A. dos Santos Costa, M. Fazel-Zarandi, T. Sercu, S. Candido, dan A. Rives. Prediksi struktur protein tingkat atom skala evolusioner dengan model bahasa. *Science*, 379:1123–1130, 3 2023. ISSN 0036-8075. doi: 10.1126/science.ade2574.

H. Liu, M. Zaharia, dan P. Abbeel. Perhatian cincin dengan transformer berbasis blok untuk konteks nyaris tak terbatas. *arXiv preprint arXiv:2310.01889*, 2023.

B. J. Livesey dan J. A. Marsh. Pembaruan tolok ukur prediktor efek varian menggunakan pemindaian mutasi mendalam. *Molecular Systems Biology*, 19, Agustus 2023. ISSN 1744-4292. doi: 10.15252/msb.202211474.

R. Lorenz, S. H. Bernhart, C. H. zu Siederdissen, H. Tafer, C. Flamm, P. F. Stadler, and I. L. Hofacker. Viennarna package 2.0. *Algorithms for Molecular Biology*, 6:26, 12 2011. ISSN 1748-7188. doi: 10.1186/1748-7188-6-26.

X. Ma, C. Zhou, X. Kong, J. He, L. Gui, G. Neubig, J. May, dan L. Zettlemoyer. Mega: perhatian tertarget yang dilenkap rata-rata bergerak. *arXiv preprint arXiv:2209.10655*, 2022.

N. B. Macfarlane, J. Adams, E. L. Bennett, T. M. Brooks, J. A. Delborne, H. Eggermont, D. Endy, K. M. Esvelt, B. K. Olodziejczyk, T. Kuiken, M. J. Oliva, S. Peña Moreno, L. Slobodian, R. B. Smith, D. Thizy, D. M. Tompkins, W. Wei, and K. H. Redford. Dampak Langsung dan Tidak Langsung Biologi Sintetis terhadap Konservasi Keanekaragaman Hayati. *iScience*, 25(11):105423, 2022. ISSN 2589-0042. doi: <https://doi.org/10.1016/j.isci.2022.105423>. URL <https://www.sciencedirect.com/science/article/pii/S2589004222016959>.

A. Madani, B. Krause, E. R. Greene, S. Subramanian, B. P. Mohr, J. M. Holton, J. L. Olmos, C. Xiong, Z. Z. Sun, R. Socher, J. S. Fraser, dan N. Naik. Model bahasa besar menghasilkan sekuens protein fungsional pada beragam famili. *Nature Biotechnology*, 41:1099–1106, 8 2023. ISSN 1087-0156. doi: 10.1038/s41587-022-01618-2.

-
- S. Massaroli, M. Poli, D. Fu, H. Kumbong, R. Parnichkun, D. Romero, A. Timalsina, Q. McIntyre, B. Chen, A. Rudra, et al. Penyulingan hyena tertawa: Mengekstraksi rekurensi kompak dari konvolusi. *Advances in Neural Information Processing Systems*, 36, 2024.
- C. Meers, H. C. Le, S. R. Pesari, F. T. Hoffmann, M. W. G. Walker, J. Gezelle, S. Tang, dan S. H. Sternberg. Nukleas e yang disandi transposon menggunakan RNA pemandu untuk mendorong penyebaran egois mereka. *Nature*, 622:863–871, 10 2023. ISSN 0028-0836. doi: 10.1038/s41586-023-06597-1.
- J. Meier, R. Rao, R. Verkuil, J. Liu, T. Sercu, dan A. Rives. Model bahasa memungkinkan prediksi zero-shot efek mu tasi terhadap fungsi protein. *Advances in Neural Information Processing Systems*, 34, 2021.
- F. Meyer, D. Paarmann, M. D'Souza, R. Olson, E. M. Glass, M. Kubal, T. Paczian, A. Rodriguez, R. Stevens, A. Wil ke, J. Wilkening, dan R. A. Edwards. Server metagenomik RAST - sumber daya publik untuk analisis filogenetik dan fungsional metagenom secara otomatis. *BMC Bioinformatics*, 9:386, Sept. 2008.
- A. L. Mitchell, A. Almeida, M. Beracochea, M. Boland, J. Burgin, G. Cochrane, M. R. Crusoe, V. Kale, S. C. Potter, L. J. Richardson, E. Sakharova, M. Scheremetjew, A. Korobeynikov, A. Shlemov, O. Kunyavskaya, A. Lapidus, dan R. D. Finn. MGnify: sumber daya analisis mikrobioma pada tahun 2020. *Nucleic Acids Res.*, 48(D1): D570–D578, Jan . 2020.
- A. Mitrofanov, M. Ziemann, O. S. Alkhnbashi, W. R. Hess, dan R. Backofen. CRISPRtracrRNA: pendekatan yang ha ndal untuk deteksi tracrRNA CRISPR. *Bioinformatics*, 38:ii42–ii48, 9 2022. ISSN 1367-4803. doi: 10.1093/ bioinfor matics/btac466.
- T. H. Morgan. Pewarisan terbatas jenis kelamin pada *Drosophila*. *Science*, 32:120–122, 7 1910. ISSN 0036-8075. doi: 10.1126/science.32.812.120.
- S. Morin, G. Segafredo, M. Piccolis, A. Das, M. Das, N. Loffredi, A. Larbi, K. Mwamelo, E. Villanueva, S. Nobre, da n E. Burrone. Memperluas akses terhadap bioterapeutik di negara-negara berpenghasilan rendah dan menengah melal ui lisensi sukarela non-eksklusif kekayaan intelektual untuk kesehatan masyarakat: pertimbangan, persyaratan, dan pe luang. *The Lancet Global Health*, 11:e145–e154, 1 2023. ISSN 2214109X. doi: 10.1016/S2214-109X(22)00460-0.
- Nature Computational Science. Jejak karbon penelitian komputasi. *Nature Computational Science*, 3:659–659, Agust us 2023. ISSN 2662-8457. doi: 10.1038/s43588-023-00506-2.
- E. P. Nawrocki dan S. R. Eddy. Infernal 1.1: 100 kali lipat lebih cepat pencarian homologi RNA. *Bioinformatics*, 29(22): 2933–2935, November 2013.
- E. Nguyen, M. Poli, M. Faizi, A. Thomas, M. Wornow, C. Birch-Sykes, S. Massaroli, A. Patel, C. Rabideau, Y. Beng io, dkk. *HyenaDNA: Pemodelan Urutan Genomik Jarak Jauh pada Resolusi Nukleotida Tunggal*. *Advances in Neural Information Processing Systems*, 36, 2023.
- M. W. Nirenberg dan J. H. Matthaei. Ketergantungan sintesis protein bebas sel dalam *E. coli* pada poliribonukleotida alami atau sintetis. *Proceedings of the National Academy of Sciences*, 47:1588–1602, 10 1961. ISSN 0027-8424. doi: 10.1073/pnas.47.10.1588.
- P. Notin, M. Dias, J. Frazer, J. M. Hurtado, A. N. Gomez, D. Marks, dan Y. Gal. Tranception: prediksi kebugaran pro tein dengan transformer autoregresif dan pengambilan saat inferensi. halaman 16990–17017, 2022.
- P. Notin, A. W. Kollasch, D. Ritter, L. van Niekerk, S. Paul, H. Spinner, N. Rollins, A. Shaw, R. Weitzman, J. Frazer, M. Dias, D. Franceschi, R. Orenbuch, Y. Gal, dan D. S. Marks. ProteinGym: Tolok Ukur Skala Besar untuk Desain P roteiin dan Prediksi Kebugaran. *bioRxiv*, halaman 2023.12.07.570727, 1 2023. doi: 10.1101/2023.12.07.570727. URL <http://biorxiv.org/content/early/2023/12/08/2023.12.07.570727.abstract>.
- N. A. O'Leary, M. W. Wright, J. R. Brister, S. Ciufu, D. Haddad, R. McVeigh, B. Rajput, B. Robbertse, B. Smith- W hite, D. Ako-Adjei, A. Astashyn, A. Badretdin, Y. Bao, O. Blinkova, V. Brover, V. Chetvernin, J. Choi, E. Cox, O. Er molaeva, C. M. Farrell, T. Goldfarb, T. Gupta, D. Haft, E. Hatcher, W. Hlavina, V. S. Joardar, V. K. Kodali, W. Li, D . Maglott, P. Masterson, K. M. McGarvey, M. R. Murphy, K. O'Neill, S. Pujar, S. H. Rangwala, D. Rausch, L. D. Rid dick, C. Schoch, A. Shkeda, S. S. Storz, H. Sun, F. Thibaud-Nissen, I. Tolstoy, R. E.
-

Tully, A. R. Vatsan, C. Wallin, D. Webb, W. Wu, M. J. Landrum, A. Kimchi, T. Tatusova, M. DiCuccio, P. Kitts, T. D. Murphy, dan K. D. Pruitt. Database sekuens referensi (RefSeq) di ncbi: status terkini, perluasan taksonomi, dan anotasi fungsional. *Nucleic Acids Research*, 44:D733–D745, 1 2016. ISSN 0305-1048. doi: 10.1093/nar/gkv1189.

A. Orvieto, S. L. Smith, A. Gu, A. Fernando, C. Gulcehre, R. Pascanu, dan S. De. Membangkitkan Kembali Jaringan Saraf Rekuren untuk Sekuens Panjang. *arXiv preprint arXiv:2303.06349*, 2023.

L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, J. S chulman, J. Hilton, F. Kelton, L. Miller, M. Simens, A. Askeel, P. Welinder, P. Christiano, J. Leike, dan R. Lowe. Me latih model bahasa untuk mengikuti instruksi dengan umpan balik manusia, 2022.

D. H. Parks, M. Imelfort, C. T. Skennerton, P. Hugenholtz, dan G. W. Tyson. Checkm: menilai kualitas genom mikro ba yang diperoleh dari isolat, sel tunggal, dan metagenom. *Genome Research*, 25:1043–1055, 7 2015. ISSN 1088-9051. doi: 10.1101/gr.186072.114.

D. H. Parks, M. Chuvochina, C. Rinke, A. J. Mussig, P.-A. Chaumeil, dan P. Hugenholtz. GTDB: sensus berkelanjuta n terhadap keanekaragaman bakteri dan arkea melalui taksonomi berbasis genom yang konsisten secara filogenetik, te rnormalisasi peringkat, dan lengkap. *Nucleic Acids Research*, 50:D785–D794, 1 2022. ISSN 0305-1048. doi: 10.1093/nar/gkab776.

M. E. Peek. Dengan cara apa pun yang diperlukan: mengapa menurunkan harga insulin relevan bagi ekuitas kesehata n rasial. *The Lancet*, 398:1783–1784, 11 2021. ISSN 01406736. doi: 10.1016/S0140-6736(21)02315-1.

J. Pilault, M. Fathi, O. Firat, C. Pal, P.-L. Bacon, dan R. Goroshin. Transformers keadaan-blok. *Advances in Neural Information Processing Systems*, 36, 2024.

J. N. Pitt dan A. R. Ferré-D’Amaré. Konstruksi cepat lanskap kebugaran RNA empiris. *Science*, 330(6002): 376–379, Okt. 2010.

D. Piya, N. Nolan, M. L. Moore, L. A. R. Hernandez, B. F. Cress, R. Young, A. P. Arkin, and V. K. Mutalik. Pemetaa n esensialitas seluruh genom yang sistematis dan dapat diskalakan untuk mengidentifikasi gen non-esensial pada fag. *PLOS Biology*, 21:e3002416, 12 2023. ISSN 1545-7885. doi: 10.1371/journal.pbio.3002416.

M. Poli, S. Massaroli, E. Nguyen, D. Y. Fu, T. Dao, S. Baccus, Y. Bengio, S. Ermon, dan C. Ré. Hyena hierarchy: M enuju model bahasa konvolusional yang lebih besar. *arXiv preprint arXiv:2302.10866*, 2023a.

M. Poli, J. Wang, S. Massaroli, J. Quesnelle, R. Carlow, E. Nguyen, dan A. Thomas. StripedHyena: Melampaui Trans formers dengan Model Pemrosesan Sinyal Hibrida, 12 2023b. URL <https://github.com/togethercomputer/stripedhyena>.

R. Rafailov, A. Sharma, E. Mitchell, C. D. Manning, S. Ermon, dan C. Finn. Optimisasi preferensi langsung: Model b ahasa Anda secara rahasia adalah model imbalan. *Advances in Neural Information Processing Systems*, 36, 2024.

H. L. Rehm, A. J. Page, L. Smith, J. B. Adams, G. Alterovitz, L. J. Babb, M. P. Barkley, M. Baudis, M. J. Beauvais, T. Beck, J. S. Beckmann, S. Beltran, D. Bernick, A. Bernier, J. K. Bonfield, T. F. Boughtwood, G. Bourque, S. R. Bo wers, A. J. Brookes, M. Brudno, M. H. Brush, D. Bujold, T. Burdett, O. J. Buske, M. N. Cabili, D. L. Cameron, R. J. Carroll, E. Casas-Silva, D. Chakravarty, B. P. Chaudhari, S. H. Chen, J. M. Cherry, J. Chung, M. Cline, H. L. Clissol d, R. M. Cook-Deegan, M. Courtot, F. Cunningham, M. Cupak, R. M. Davies, D. Denisko, M. J. Doerr, L. I. Dolman, E. S. Dove, L. J. Dursi, S. O. Dyke, J. A. Eddy, K. Eilbeck, K. P. Ellrott, S. Fairley, K. A. Fakhro, H. V. Firth, M. S. Fitzsimons, M. Fiume, P. Flicek, I. M. Fore, M. A. Freeberg, R. R. Freimuth, L. A. Fromont, J. Fuerth, C. L. Gaff, W. Gan, E. M. Ghanaim, D. Glazer, R. C. Green, M. Griffith, O. L. Griffith, R. L. Grossman, T. Groza, J. M. G. Auvil, R . Guigó, D. Gupta, M. A. Haendel, A. Hamosh, D. P. Hansen, R. K. Hart, D. M. Hartley, D. Haussler, R. M. Hendrick s-Sturrrup, C. W. Ho, A. E. Hobb, M. M. Hoffman, O. M. Hofmann, P. Holub, J. S. Hsu, J.-P. Hubaux, S. E. Hunt, A. Husami, J. O. Jacobsen, S. S. Jamuar, E. L. Janes, F. Jeanson, A. Jené, A. L. Johns, Y. Joly, S. J. Jones, A. Kanitz, K. Kato, T. M. Keane, K. Kekesi-Lafrance, J. Kelleher, G. Kerry, S.-S. Khor, B. M. Knoppers, M. A. Konopko, K. Kosa ki, M. Kuba, J. Lawson, R. Leinonen, S. Li, M. F. Lin, M. Linden, X. Liu, I. U. Liyanage, J. Lopez, A. M. Lucassen, M. Lukowski, A. L. Mann, J. Marshall, M. Mattioni, A. Metke-Jimenez, A. Middleton, R. J. Milne, F. Molnár-Gábor, N. Mulder, M. C. Munoz-Torres,

R. Nag, H. Nakagawa, J. Nasir, A. Navarro, T. H. Nelson, A. Niewielska, A. Nisselle, J. Niu, T. H. Nyrönen, B. D. O'Connor, S. Oesterle, S. Ogishima, V. O. Wang, L. A. Paglione, E. Palumbo, H. E. Parkinson, A. A. Philippakis, A. D. Pizarro, A. Prlic, J. Rambla, A. Rendon, R. A. Rider, P. N. Robinson, K. W. Rodarmer, L. L. Rodriguez, A. F. Rubin, M. Rueda, G. A. Rushton, R. S. Ryan, G. I. Saunders, H. Schuilenburg, T. Schwede, S. Scollen, A. Senf, N. C. Sheffield, N. Skantharajah, A. V. Smith, H. J. Sofia, D. Spalding, A. B. Spurdle, Z. Stark, L. D. Stein, M. Sue matsu, P. Tan, J. A. Tedds, A. A. Thomson, A. Thorogood, T. L. Tickle, K. Tokunaga, J. Törnroos, D. Torrents, S. Upchurch, A. Valencia, R. V. Guimera, J. Vamathevan, S. Varma, D. F. Vears, C. Viner, C. Voisin, A. H. Wagner, S. E. Wallace, B. P. Walsh, M. S. Williams, E. C. Winkler, B. J. Wold, G. M. Wood, J. P. Woolley, C. Yamasaki, A. D. Yates, C. K. Yung, L. J. Zass, K. Zaytseva, J. Zhang, P. Goodhand, K. North, dan E. Birney. GA4GH: Kebija kan dan standar internasional untuk berbagi data di seluruh penelitian genomik dan layanan kesehatan. *Cell Genomics*, 1:100029, 11 2021. ISSN 2666979X. doi: 10.1016/j.xgen.2021.100029.

A. Rives, J. Meier, T. Sercu, S. Goyal, Z. Lin, J. Liu, D. Guo, M. Ott, C. L. Zitnick, J. Ma, dan R. Fergus. Struktur dan fungsi biologis muncul dari penskalaan pembelajaran tanpa pengawasan hingga 250 juta sekuens protein. *Proceedings of the National Academy of Sciences*, 118:e2016239118, 2021. ISSN 0027-8424. doi: 10.1073/pnas.2016239118.

E. P. C. Rocha dan A. Danchin. Esensialitas gen menentukan organisasi kromosom pada bakteri. *Nucleic Acids Research*, 31:6570–6577, 11 2003. ISSN 1362-4962. doi: 10.1093/nar/gkg859.

D. W. Romero, A. Kuzina, E. J. Bekkers, J. M. Tomczak, dan M. Hoogendoorn. Ckconv: Konvolusi kernel kontinu untuk data sekuensial. *arXiv preprint arXiv:2102.02611*, 2021.

J. Russel, R. Pinilla-Redondo, D. Mayo-Muñoz, S. A. Shah, dan S. J. Sørensen. CRISPRCasTyper: Identifikasi, anotasi, dan klasifikasi otomatis lokus CRISPR-Cas. *CRISPR J*, 3(6):462–469, Des. 2020. Schrödinger, LLC. Sistem grafis molekuler PyMOL, versi 1.8. Nov. 2015. T. Seemann. barnap, 2018.

N. Shazeer. Varian Glu Meningkatkan Transformer. *arXiv preprint arXiv:2002.05202*, 2020.

R. A. Silverstein, S. Sun, M. Verby, J. Weile, Y. Wu, M. Gebbia, I. Fotiadou, J. Kitaygorodsky, dan F. P. Roth. Peta genotipe-fenotipe sistematis untuk varian missense pada gen GDI1 yang terkait disabilitas intelektual manusia. *bioRxiv*, halaman 2021.10.06.463360, 1 2022. doi: 10.1101/2021.10.06.463360. URL <http://biorxiv.org/content/early/2022/10/11/2021.10.06.463360.abstract>. M. Steinegger dan J. Söding. MMseqs2 memungkinkan pencarian sekuens protein yang sensitif untuk analisis kumpulan data masif. *Nat. Biotechnol.*, 35(11):1026–1028, Nov. 2017.

J. Su, M. Ahmed, Y. Lu, S. Pan, W. Bo, dan Y. Liu. Roformer: Transformer yang ditingkatkan dengan rotary position embedding. *Neurocomputing*, 568:127063, 2024.

S. Sun, J. Weile, M. Verby, Y. Wu, Y. Wang, A. G. Cote, I. Fotiadou, J. Kitaygorodsky, M. Vidal, J. Rine, P. Ješina, V. Kožich, dan F. P. Roth. Peta genotipe-ke-fenotipe-pasien proaktif untuk sistationin beta-sintase. *Genome Medicine*, 12:13, 12 2020. ISSN 1756-994X. doi: 10.1186/s13073-020-0711-1.

S. Sunagawa, L. P. Coelho, S. Chaffron, J. R. Kulima, K. Labadie, G. Salazar, B. Djahanschiri, G. Zeller, D. R. Men de, A. Alberti, F. M. Cornejo-Castillo, P. I. Costea, C. Cruaud, F. d'Ovidio, S. Engelen, I. Ferrera, J. M. Gasol, L. Guidi, F. Hildebrand, F. Kokoszka, C. Lepoivre, G. Lima-Mendez, J. Poulain, B. T. Poulos, M. Royo-Llonch, H. Sarmiento, S. Vieira-Silva, C. Dimier, M. Picheral, S. Searson, S. Kandels-Lewis, Tara Oceans coordinators, C. Bowler, C. de Vargas, G. Gorsky, N. Grimsley, P. Hingamp, D. Iudicone, O. Jaillon, F. Not, H. Ogata, S. Pesant, S. Speich, L. Stemmann, M. B. Sullivan, J. Weissenbach, P. Wincker, E. Karsenti, J. Raes, S. G. Acinas, dan P. Bork. Plankton laut, struktur dan fungsi mikrobioma laut global. *Science*, 348(6237):1261359, Mei 2015.

Y. Tay, V. Q. Tran, S. Ruder, J. Gupta, H. W. Chung, D. Bahri, Z. Qin, S. Baumgartner, C. Yu, dan D. Metzler. Chformer: Transformer karakter cepat melalui tokenisasi subkata berbasis gradien. *arXiv preprint arXiv:2106.12672*, 2021.

C. V. Theodoris, L. Xiao, A. Chopra, M. D. Chaffin, Z. R. A. Sayed, M. C. Hill, H. Mantineo, E. M. Brydon, Z. Zeng, X. S. Liu, and P. T. Ellinor. Transfer learning memungkinkan prediksi dalam biologi jaringan. *Nature*, 618: 616–624, 6 2023. ISSN 0028-0836. doi: 10.1038/s41586-023-06139-9.

Analisis eksperimental skala mega stabilitas pelipatan protein dalam biologi dan desain. *Nature*, 620:434–444, 8 2023. ISSN 0028-0836. doi: 10.1038/s41586-023-06328-6.

K. H. Turner, A. K. Wessel, G. C. Palmer, J. L. Murray, dan M. Whiteley. Genom Esensial **Pseudomonas aeruginosa* * dalam Dahak Fibrosis Kistik. *Proceedings of the National Academy of Sciences*, 112:4110–4115, Maret 2015. ISSN 0027-8424. doi: 10.1073/pnas.1419677112.

J. Y. Wang, P. Pausch, dan J. A. Doudna. Biologi struktural imunitas CRISPR-Cas dan enzim penyunting genom. *Nature Reviews Microbiology*, 20:641–656, 11 2022. ISSN 1740-1526. doi: 10.1038/s41579-022-00739-4.

J. Watson dan F. Crick. Struktur molekuler asam nukleat: Struktur untuk asam deoksiribonukleat. *Nature*, 171:737–738, 4 1953. ISSN 0028-0836. doi: 10.1038/171737a0.

J. L. Watson, D. Juergens, N. R. Bennett, B. L. Trippe, J. Yim, H. E. Eisenach, W. Ahern, A. J. Borst, R. J. Ragotte, L. F. Milles, B. I. M. Wicky, N. Hanikel, S. J. Pellock, A. Courbet, W. Sheffler, J. Wang, P. Venkatesh, I. Sappington, S. V. Torres, A. Lauko, V. D. Bortoli, E. Mathieu, S. Ovchinnikov, R. Barzilay, T. S. Jaakkola, F. DiMaio, M. Baek, and D. Baker. Desain de novo struktur dan fungsi protein dengan rfdiffusion. *Nature*, 620:1089–1100, 8 2023. ISSN 0028-0836. doi: 10.1038/s41586-023-06415-8.

R. Weeks dan M. Ostermeier. Lanskap fitness dan fungsional dari gen *E. coli* RNase III rnc. *Molecular Biology and Evolution*, 40, 3 2023. ISSN 0737-4038. doi: 10.1093/molbev/msad047.

J. Wei, M. Bosma, V. Zhao, K. Guu, A. W. Yu, B. Lester, N. Du, A. M. Dai, dan Q. V. Le. Model bahasa yang disetel ulang adalah pembelajar zero-shot. 2022. URL <https://openreview.net/forum?id=gEZrGCozdqR>.

J. Wei, P. Lotfy, K. Faizi, S. Baungaard, E. Gibson, E. Wang, H. Slabodkin, E. Kinnaman, S. Chandrasekaran, H. Kitano, M. G. Durrant, C. V. Duffy, A. Pawluk, P. D. Hsu, dan S. Konermann. Deep learning dan penemuan ortolog CRISPR-Cas13d untuk penargetan RNA yang dioptimalkan. *Cell Syst*, 14(12):1087–1102.e13, Des 2023.

W. Xiong, J. Liu, I. Molybog, H. Zhang, P. Bhargava, R. Hou, L. Martin, R. Rungta, K. A. Sankararaman, B. Oguz, et al. Penskalaan konteks panjang yang efektif dari model fondasi. *arXiv preprint arXiv:2309.16039*, 2023.

K. K. Yang, N. Fusi, dan A. X. Lu. Konvolusi kompetitif dengan transformer untuk pra-pelatihan sekuens protein. *bioRxiv*, 2024. doi: 10.1101/2022.05.19.492714. URL <https://www.biorxiv.org/content/early/2024/02/05/2022.05.19.492714>.

J. Ye, S. McGinnis, dan T. L. Madden. BLAST: peningkatan untuk analisis sekuens yang lebih baik. *Nucleic Acids Res.*, 34(edisi Server Web):W6–9, Juli 2006.

N. D. Youngblut, J. de la Cuesta-Zuluaga, G. H. Reischer, S. Dauser, N. Schuster, C. Walzer, G. Stalder, A. H. Farnleitner, dan R. E. Ley. Perakitan metagenom skala besar mengungkap genom mikroba baru yang terkait hewan, kluster gen biosintetik, dan keragaman genetik lainnya. *mSystems*, 5(6), Nov. 2020.

B. Zhang dan R. Sennrich. Normalisasi Lapisan Akar Rata-rata Kuadrat. *Advances in Neural Information Processing Systems*, 32, 2019.

M. Zhang, K. K. Saab, M. Poli, T. Dao, K. Goel, dan C. Ré. Pemodelan deret waktu secara efektif dengan ruang keadaan diskret sederhana. *arXiv preprint arXiv:2303.09489*, 2023.

R. Zhang. DEG: basis data gen esensial. *Nucleic Acids Research*, 32:271D–272, Januari 2004. ISSN 1362-4962. doi: 10.1093/nar/gkh024.

Z. D. Zhang, M. Nayar, D. Ammons, J. Rampersad, dan G. E. Fox. Eksplorasi in vivo cepat jejaring netral rRNA 5S. *J. Microbiol. Methods*, 76(2):181–187, Feb. 2009.

Z. Zhou, Y. Ji, W. Li, P. Dutta, R. Davuluri, dan H. Liu. DNABERT-2: Model dasar dan tolok ukur yang efisien untuk genom multispecies. *arXiv preprint arXiv:2306.15006*, 2023.

M. Zvyagin, A. Brace, K. Hippe, Y. Deng, B. Zhang, C. O. Bohorquez, A. Clyde, B. Kale, D. Perez-Rivera, H. Ma, C. M. Mann, M. Irvin, D. G. Ozgulbas, N. Vassilieva, J. G. Pauloski, L. Ward, V. Hayot-Sasson, M. Emani, S. Foreman, Z. Xie, D. Lin, M. Shukla, W. Nie, J. Romero, C. Dallago, A. Vahdat, C. Xiao, T. Gibbs, I. Foster, J. J. Davis, M. E. Papka, T. Bretin, R. Stevens, A. Anandkumar, V. Vishwanath, dan A. Ramanathan. GenSLMs: Model bahasa skala genom mengungkap dinamika evolusi SARS-CoV-2. *The International Journal of High Performance Computing Applications*, 37:683–705, 11 2023. ISSN 1094-3420. doi: 10.1177/10943420231201154.

Pemodelan dan desain sekuens dari skala molekuler hingga genom dengan Evo

Supplementary Material

Daftar Isi

1 Pendahuluan	1
2 Hasil	3
2.1 Pemodelan sekuens panjang pada resolusi nukleotida dengan arsitektur StripedHyena	32.2 Pelatihan Evo
o skala besar pada OpenGenome	42.3 StripedHyena menunjukkan hukum p
enskalaan yang menguntungkan pada data sekuens DNA	42.4 Evo melakukan prediksi fungsi zero-shot lin
tas modalitas DNA, RNA, dan protein	42.4.1 Prediksi efek mutasi pada fungsi protein
.	42.4.2 Prediksi efek mutasi pada fungsi ncRNA
.	62.4.3 Predik
si ekspresi gen dari DNA regulatoris	62.5 Desain generatif kompleks molekuler C
RISPR-Cas	72.6 Desain generatif sistem biologis transposable
.	92.7 Prediksi esensialitas gen dengan konteks genomik panjang
.	9
2.8 Generasi sekuens DNA pada skala genom	12
3 Pembahasan	14
4 Kode dan ketersediaan data	16
5 Ucapan Terima Kasih	16
6 Kontribusi Penulis	16
7 Konflik Kepentingan	16
A Pembahasan Keselamatan dan Etika	30
A.1 Implikasi keamanan dan etika	30A.1.1 Model fondasi genom utuh berpot
ensi disalahgunakan	30A.1.2 Model fondasi genom utuh dapat berkontribusi pada ketidaksetaraan
sosial dan kesehatan	30

A.1.3 Model fondasi genom utuh dapat berkontribusi terhadap gangguan pada lingkungan alam	30
A.2 Langkah ke Depan	31
B Metode	32
B.1 Arsitektur StripedHyena	32
B.2 Dataset OpenGenome	32
B.3 Prosedur Pelatihan	33
B.4 Hukum Penskalaan	34
B.5 Menghasilkan Sekuens DNA dengan Evo	34
B.6 Evaluasi Multimodal	36
B.6.1 Prediksi Fungsi Protein	36
B.6.2 Prediksi Fungsi ncRNA	37
B.6.3 Prediksi Ekspresi Gen dari DNA Regulator	37
B.7 Penyetelan, Pembangkitan, dan Analisis Hilir CRISPR-Cas	37
B.8 Penyetelan, Pembangkitan, dan Analisis Hilir IS200/IS605	38
B.9 Prediksi Esensialitas Gen	39
B.10 Pembangkitan dan Evaluasi Skala Genom	40
C Tabel dan Gambar Suplemen	41

A. Pembahasan keamanan dan etika

Pengenalan model fondasi genomik generatif yang kuat seperti Evo memungkinkan penguraian cepat informasi genetik kompleks, yang dapat digunakan untuk rekayasa genetika dan pengembangan terapeutik. Evo adalah yang pertama dari jenisnya yang dapat memprediksi dan menghasilkan sekuens DNA pada skala seluruh genom dengan resolusi nukleotida tunggal, meskipun hanya untuk prokariota pada versi ini. Karena peningkatan kemampuan di masa depan kemungkinan besar dapat dicapai dengan kelas model DNA skala besar yang dimungkinkan oleh Evo, kami menyajikan diskusi etis yang diperluas mengenai risiko potensial dan tindakan pencegahan. Meskipun Evo masih terbatas dalam bentuknya saat ini, desain molekuler, sintesis, manipulasi, dan penyebaran materi genetik sintetis baru dapat menimbulkan kekhawatiran bagi individu, masyarakat, dan lingkungan. Melalui lensa AI yang bertanggung jawab (Badal et al., 2023), kami memperkirakan tiga implikasi etis yang menonjol dan mengidentifikasi solusi mediasi.

A.1. Keamanan dan implikasi etis

A.1.1. *Whole-genome foundation models have the potential for misuse*

Terdapat kekhawatiran bahwa penggunaan ganda (atau penyalahgunaan) model fondasi genomik oleh aktor jahat dapat menimbulkan ancaman terhadap biosafety dan biokeamanan (Baker dan Church, 2024). Perangkat seperti Evo berfungsi untuk meningkatkan kueri terhadap basis pengetahuan genomik yang ada dan mengidentifikasi daerah genetik yang diminati untuk disunting atau dieksperimenkan. Kemampuan untuk memahami kebugaran yang terkait dengan sekuens tertentu dapat membantu penemuan biomarker baru atau target terapeutik, tetapi juga dapat memicu pengembangan mikroorganisme sintetis berbahaya yang lebih mudah melewati pertahanan alami tubuh, resisten terhadap pengobatan yang ada, atau menyebabkan penyakit yang lebih parah. Untungnya, bahkan dengan desain genom sintetis yang optimal, kemampuan untuk menciptakan organisme yang viable dibatasi oleh hambatan masuk yang tinggi, termasuk banyaknya sumber daya teknis dan keahlian yang diperlukan untuk melakukan sintesis dan ekspresi genom, yang semakin diperburuk oleh ketidakpastian mekanisme biologis. Meskipun demikian, seiring dengan semakin mudahnya akses terhadap perangkat rekayasa genetika, pagar pengaman (misalnya, kontrol akses, audit penggunaan) harus disepakati oleh para pemangku kepentingan untuk membatasi kueri tanpa kendali terhadap sekuens genetik berbahaya. Definisi yang jelas tentang apa yang dimaksud dengan "penyalahgunaan ganda" juga diperlukan untuk memberikan batasan bagi peneliti, pembuat kebijakan, dan pemangku kepentingan lainnya.

A.1.2. *Whole-genome foundation models could contribute to social and health inequity*

Mengingat tingginya hambatan untuk masuk, ketimpangan akses dan kapabilitas terhadap alat seperti Evo dapat menyebabkan kerugian sosial yang tidak disengaja. Evo bersifat sumber terbuka untuk mendorong transparansi dan penelitian yang dapat direproduksi. Namun, pihak yang paling efektif dapat menggunakan, dan karenanya paling banyak memperoleh manfaat dari, alat tersebut adalah entitas dengan sumber daya dan keahlian bioteknologi yang terkoordinasi, seperti perusahaan bioteknologi dan farmasi. Perusahaan-perusahaan ini dapat mempercepat penelitian ke arah yang lebih memprioritaskan imbal hasil investasi di atas beban penyakit global atau kesetaraan kesehatan (Morin et al., 2023). Sejalan dengan itu, negara-negara yang lebih kaya atau lembaga-lembaga dengan pendanaan lebih besar juga berpotensi lebih baik memanfaatkan Evo untuk mempercepat agenda penelitian mereka, semakin memperlebar kesenjangan antara lingkungan dengan sumber daya tinggi dan rendah.

Penggunaan perangkat generatif dalam biologi juga menimbulkan kekhawatiran kompleks terkait kekayaan intelektual. Model dasar biologis seperti Evo dapat memungkinkan suatu organisasi untuk menghindari batasan kekayaan intelektual saat ini pada terapi biologis atau bahan lainnya. Dalam beberapa kasus, hal ini dapat menyebabkan monopoli pengobatan untuk kondisi tertentu. Entitas tersebut kemudian dapat menggunakan hak ini untuk menetapkan harga yang sangat tinggi dan membuat pengobatan tidak terjangkau bagi sebagian besar pasien (misalnya, mereka yang berada di negara berpenghasilan rendah), sehingga semakin memperburuk kesenjangan kesehatan (Peek, 2021). Dalam kasus lain, menghindari perlindungan kekayaan intelektual dapat menghambat investasi lebih lanjut dalam inovasi terapi. Secara keseluruhan, kami berpendapat bahwa entitas yang menggunakan dan memperoleh manfaat dari perangkat sumber terbuka seperti Evo memiliki kewajiban untuk mengembalikan nilai kepada publik dan berkontribusi pada kesetaraan sosial dan kesehatan. Hukum kekayaan intelektual juga harus berkembang seiring dengan model generatif yang semakin mengotomatiskan proses penemuan dan perancangan biologis.

A.1.3. *Whole-genome foundation models could contribute to disruptions to the natural environment*

AMeskipun Evo tidak secara langsung memanipulasi materi genetik apa pun, Evo mungkin meningkatkan efisiensi rekayasa genetika proyek rekayasa. Terdapat kekhawatiran tentang bagaimana kemampuan teknologi rekayasa genetika dapat mengganggu lingkungan dan menyebabkan ketidakpastian ekologis (misalnya, pelepasan organisme yang diubah), yang mengarah ke

hilangnya keanekaragaman hayati atau munculnya spesies baru yang berpotensi merugikan (Macfarlane et al., 2022). Meskipun dampak ekologis dari pelatihan model fondasi genom utuh masih belum diketahui, dalam jangka pendek, penting pula untuk mempertimbangkan jejak karbon yang terkait dengan peningkatan infrastruktur dan kebutuhan komputasi (Nature Computational Science, 2023). Kemampuan alat seperti Evo, bersama dengan teknologi lain untuk penyuntingan genom dan rekayasa ekologi, menambah kerumitan perdebatan tentang sejauh mana sains seharusnya mengintervensi evolusi. Saat kita mendorong batas kemampuan ilmiah dengan alat seperti Evo, menjadi imperatif untuk merefleksikan interaksi dan batas antara penemuan kita dan proses evolusi alami, dengan tujuan menjaga keseimbangan ekologi, mempertahankan keberlanjutan lingkungan, dan menjunjung tinggi standar etika.

A.2. Langkah ke Depan

Jalan ke depan untuk penggunaan dan pengembangan yang bertanggung jawab atas alat seperti Evo didasarkan pada penetapan pedoman yang jelas dan komprehensif yang menguraikan praktik etis. Pedoman ini berfungsi sebagai kerangka kerja AI yang bertanggung jawab, memastikan bahwa semua pemangku kepentingan—peneliti, pengembang, dan pengguna—memiliki pemahaman bersama tentang dimensi keamanan dan etika yang melekat dalam rekayasa genetika. Ditambah dengan mekanisme pengawasan yang kuat, pendekatan ini bertujuan untuk memantau dan mengelola penerapan Evo guna mencegah penyalahgunaan dan memastikan keselarasannya dengan standar etika. Lebih lanjut, mempromosikan transparansi mengenai penggunaan teknologi ini dan mendorong dialog terbuka di antara semua pihak akan meningkatkan kepercayaan dan kolaborasi di dalam komunitas ilmiah dan di luarnya.

Untuk mengatasi disparitas dalam akses dan kapabilitas, khususnya di negara-negara berpenghasilan rendah, strategi ini mencakup pembentukan kemitraan komunitas dan kolaborasi internasional. Dengan menawarkan pelatihan dan dukungan yang terarah, kemitraan ini dapat mendemokratisasi akses ke perangkat canggih seperti Evo, memungkinkan spektrum ilmuwan dan peneliti yang lebih luas untuk berkontribusi pada dan memperoleh manfaat dari inovasi rekayasa genetika. Pada tataran kebijakan, investasi dalam pendidikan dan pengembangan kapasitas muncul sebagai elemen penting, membekali ilmuwan generasi mendatang dengan ketajaman etika dan keterampilan teknis untuk menangani kompleksitas penelitian genetika secara bertanggung jawab.

Inti dari menjaga keberlanjutan inovasi yang beretika adalah penciptaan lingkaran umpan balik dinamis yang melibatkan semua pemangku kepentingan dalam dialog berkesinambungan. Dengan membangun mekanisme untuk mengumpulkan dan mengintegrasikan umpan balik dari pihak-pihak yang terlibat dalam atau terdampak oleh aplikasi Evo, proses ini memastikan bahwa pedoman, kebijakan, dan praktik secara berkala disempurnakan sebagai respons terhadap tantangan etika dan harapan masyarakat yang terus berkembang. Berkolaborasi dengan organisasi seperti Global Alliance for Genomics and Health (GA4GH) (Rehm et al., 2021) untuk menyusun dan memperbarui pedoman rekayasa genetika semakin memperkuat komitmen terhadap keunggulan etika ini. Pendekatan multifaset ini tidak hanya mengatasi kekhawatiran yang mendesak, tetapi juga meletakkan fondasi bagi masa depan di mana kemajuan rekayasa genetika berjalan selaras dengan prinsip-prinsip etika dan nilai-nilai kemasyarakatan.

B. Metode

B.1. StripedHyena arsitektur

Evo didasarkan pada StripedHyena (Poli et al., 2023a), arsitektur model hibrida mutakhir untuk pemodelan sekuens. Evo terdiri dari 32 blok dengan lebar model 4096 dimensi. Setiap blok berisi lapisan pencampuran sekuens, yang bertugas memproses informasi di sepanjang dimensi sekuens, dan lapisan pencampuran saluran, yang berfokus pada pemrosesan informasi di sepanjang dimensi lebar model. Pada lapisan pencampuran sekuens, Evo menggunakan 29 lapisan hyena, diselingi dengan 3 lapisan self-attention rotary (Su et al., 2024) pada interval yang sama. Kami memparametrisasi konvolusi pada operator hyena menggunakan bentuk kanonis modal yang dijelaskan dalam (Massaroli et al., 2024). Untuk lapisan pencampuran saluran, Evo menggunakan unit linear tergerbang (Dauphin et al., 2017; Shazeer, 2020). Evo selanjutnya menormalisasi masukan ke setiap lapisan menggunakan normalisasi lapisan akar rata-rata kuadrat (Zhang dan Sennrich, 2019).

Lapisan Hyena Hyena (Poli et al., 2023a) adalah pencampur sekuens yang mengimplementasikan operator bergantung masukan (terkontrol data) melalui komposisi konvolusi pendek, konvolusi panjang, dan penggatingan (Gambar 1B). Hyena termasuk dalam kelas primitif pemrosesan sinyal dalam (Poli et al., 2023a; Fu et al., 2024; Massaroli et al., 2024), yang dirancang untuk komputasi bergantung masukan yang efisien pada model sekuens skala besar. Ketergantungan pada masukan memungkinkan arsitektur yang dibangun dengan lapisan pemrosesan sinyal dalam untuk menyesuaikan komputasi berdasarkan masukan, sehingga memungkinkan pembelajaran dalam konteks (Arora et al., 2023; Bhattachamishra et al., 2023). Lapisan ini mengandalkan operator terstruktur yang kompatibel dengan algoritma perkalian cepat dan dengan demikian dapat dievaluasi dalam waktu subkuadratik menggunakan, misalnya, Transformasi Fourier Cepat untuk konvolusi. Operator-operator tersebut diparametrisasi *implicitly*, misalnya, mempelajari pemetaan dari penyematan posisional, atau masukan, ke parameter operator. Pilihan umum parametrisasi implisit adalah proyeksi linear, hypernetwork (Romero et al., 2021; Poli et al., 2023a), atau model ruang keadaan linear dalam bentuk modal atau pendamping (Gupta et al., 2022; Gu et al., 2022; Massaroli et al., 2024; Orvieto et al., 2023; Zhang et al., 2023). Cetak biru lintas maju operator hyena dirangkum di bawah ini.

Algoritme 1 ConvProjection

Diperlukan: Sekuens masukan $u \in \mathbb{R}^{L \times D}$, dimensi dalam D_e

1. Secara paralel pada L : $\hat{z} = \text{Linear}(u)$, $\text{Linear} : \mathbb{R}^D \rightarrow \mathbb{R}^{3D_e}$
2. Secara paralel pada D_e : $z = \text{DepthwiseConv1d}(h, \hat{z})$, h adalah filter konvolusi pendek
3. Bentuk ulang dan bagi z menjadi q, k, v . Dimensi dari satu elemen adalah $q \in \mathbb{R}^{D_e \times L}$

Kembalikan q, k, v

Algoritme 3 Propagasi Maju

Diperlukan: Sekuens masukan $u \in \mathbb{R}^{L \times D}$, orde N , lebar model D , panjang sekuens L , dimensi dalam D_e

1. $q, k, v = \text{ConvProjection}(u)$
2. $h = \text{ImplicitFilter}(L)$
3. Secara paralel: $v \leftarrow k \cdot v$
4. Secara paralel di D_e : $v_t \leftarrow \text{FFTConv}(h, v)_t$
5. Secara paralel: $v \leftarrow q \cdot v$

Kembalikan $y = v$

Lapisan Self-attention Self-attention adalah operator pencampuran sekuens inti dari model Transformer. Self-attention membangun sekuens keluaran sebagai kombinasi tertimbang dari elemen-elemen masukan, di mana bobotnya sendiri bergantung pada masukan. Diberikan sekuens masukan, forward pass dari lapisan self-attention (yang tidak dinormalisasi) adalah:

$$(q, k, v) \mapsto A(q, k)v, \quad A(q, k) = \text{softmax}(qk^T)$$

di mana kueri $q \in \mathbb{R}^{L \times D}$ dan kunci $k \in \mathbb{R}^{L \times D}$ serta nilai $v \in \mathbb{R}^{L \times D}$ diperoleh melalui transformasi linear dari masukan, misalnya, $v = uW_v$. Softmax diterapkan pada baris dari A . Terminologi kueri, kunci, nilai dipinjam dari basis data, di mana kunci digunakan untuk mengindeks nilai yang disimpan. Secara konseptual, nilai-nilai dari matriks perhatian $A(q, k)$ mengukur kemiripan antara kueri dan kunci serupa dengan mencocokkan kueri dengan kunci dalam basis data.

Embedding PosisionalOperator self-attention itu sendiri tidak memiliki pemahaman tentang perbedaan posisi embedding masukan dalam suatu urutan masukan. Oleh karena itu, operator ini umumnya dilengkapi dengan mekanisme penyandian posisional. Lapisan attention StripedHyena memanfaatkan mekanisme embedding posisi rotari (RoPE) untuk memodelkan informasi posisi relatif (Su et al., 2024). Informasi posisi disandikan dengan memutar vektor token query dan key dari operator attention. Secara spesifik, RoPE menerapkan rotasi pada query dan key, dengan besaran rotasi didefinisikan sebagai fungsi dari posisi relatifnya dalam urutan.

Untuk memperluas panjang jendela konteks dari 8k ke 131k pada tahap pra-pelatihan kedua kami, kami menerapkan interpolasi posisi linear untuk memperpanjang rotary position embedding yang diterapkan pada tahap pra-pelatihan pertama pada panjang sekuens 8k (untuk detailnya, lihat Chen et al. (2023)). Interpolasi memungkinkan model untuk terus memanfaatkan representasi yang telah dipelajarinya ketika diterapkan pada sekuens yang lebih panjang daripada yang digunakan untuk melatihnya semula. Kami juga menguji metode interpolasi posisi lainnya tetapi menemukan bahwa metode tersebut bekerja sedikit lebih buruk daripada interpolasi linear pada data kami.

Tokenisasi Dalam pemodelan bahasa, token mendeskripsikan unit informasi semantik terkecil yang digunakan oleh model untuk memproses bahasa. Sebagai contoh, token dapat menunjukkan kata-kata individual dari suatu kosakata atau bahkan informasi semantik tingkat lebih rendah seperti karakter individual. Tokenisasi mendeskripsikan proses pemetaan unit-unit bahasa semantik ini, seperti kata atau karakter, ke nilai integer unik, yang masing-masing menunjukkan suatu entri dalam tabel pencarian. Nilai-nilai integer ini dipetakan oleh lapisan penyematan menjadi vektor, yang kemudian diproses oleh model secara ujung ke ujung. Evo melakukan tokenisasi sekuens DNA pada resolusi nukleotida tunggal, menggunakan penyandian UTF-8 yang diimplementasikan di Python. Selama prapelatihan, Evo menggunakan kosakata efektif sebanyak empat token, masing-masing satu per basa, dari total kosakata 512 karakter. Kami menggunakan karakter tambahan untuk memungkinkan pemberian prompt dengan token khusus selama generasi dengan model yang telah disetel halus.

B.2. Dataset OpenGenome

Dataset prapelatihan OpenGenome (S3 untuk statistik ringkasan) disusun dari tiga sumber berbeda: 1) genom bakteri dan arkea dari Basis Data Taksonomi Genom (GTDB) v214.1 (Parks et al., 2015), 2) virus prokariotik terkurasi dari basis data IMG/VR v4 (Camargo et al., 2023), dan 3) sekuens plasmid dari basis data IMG/PR (Camargo et al., 2024). Untuk GTDB, genom perwakilan setiap spesies dipertahankan untuk mengurangi redundansi data.

Untuk IMG/PR, hanya satu perwakilan per unit taksonomi plasmid (PTU) yang dipertahankan. Untuk IMG/VR, sekuens dipertahankan hanya jika diberi label "Keyakinan Tinggi" menurut metadata basis data, dan hanya satu perwakilan per unit taksonomi operasional virus (vOTU) yang dipertahankan. Sekuens-sekuens ini selanjutnya dikurasi untuk menghilangkan potensi virus eukariotik dengan hanya mempertahankan sekuens yang klasifikasi taksonomi yang ditetapkan padanya ditemukan pada inang prokariotik setidaknya dua kali. Selanjutnya, klasifikasi taksonomi yang tersisa diperiksa dan disaring lebih lanjut untuk mengecualikan semua virus yang diklasifikasikan ke dalam salah satu dari 19 famili (Adenoviridae, Caliciviridae, Coronaviridae, Filoviridae, Flaviviridae, Hantaviridae, Hepadnaviridae, Herpesviridae, Orthomyxoviridae, Papillomaviridae, Paramyxoviridae, Picornaviridae, Poxviridae, Reoviridae, Retroviridae, Rhabdoviridae, Circoviridae, Geminiviridae, Picobirnaviridae) atau 12 ordo (Amarillovirales, Durnavirales, Geplafuvirales, Herpesvirales, Lefavirales, Ortervirales, Orthopolintovirales, Piccovirales, Picornavirales, Priklausovirales, Cirlivirales, Mulpavirales). Selanjutnya, virus dengan spesifisitas taksonomi rendah dikeluarkan, termasuk yang tidak memiliki realm yang ditetapkan sama sekali, dan yang hanya ditetapkan hingga tingkat r:Riboviria, r:Monodnaviria, k:Heunggongvirae, k:Bamfordvirae, p:Preplasmiviricota, p:Cressdnaviricota, p:Pisuviricota, atau c:Tectiliviricetes.

Dataset fine-tuning CRISPR/Cas dan IS200/IS605 dikompilasi dari basis data kustom yang telah dideskripsikan sebelumnya dan dikumpulkan dari berbagai sumber (Wei et al., 2023). Secara singkat, basis data kustom ini mencakup data sekuens genomik dan metagenomik dari NCBI RefSeq (O'Leary et al., 2016), UHGG (Almeida et al., 2021), JGI IMG (Chen et al., 2021), Gut Phage Database (Camarillo-Guerrero et al., 2021), Human Gastrointestinal Bacteria Genome Collection (Forster et al., 2019), MGnify (Mitchell et al., 2020), metagenom usus hewan Youngblut et al. (2020), MGRAST (Meyer et al., 2008), dan sampel Tara Oceans (Sunagawa et al., 2015).

Untuk menyusun lokus genomik CRISPR/Cas, basis data khusus ini ditelusuri menggunakan model profil HMM dan paket perangkat lunak HMMER untuk mengidentifikasi sekuens Cas9, Cas12, dan Cas13 (Finn et al., 2011). Beberapa pHMM dikumpulkan dari alat anotasi CRISPRCasTyper (Russel et al., 2020), dan sebuah kom- terbaru

survei komputasional terhadap TnpB dan Cas12 (Altae-Tran et al., 2023). pHMM Cas13 kustom yang sebelumnya dihasilkan oleh kelompok kami juga digunakan (Wei et al., 2023). Model-model ini ditelusuri terhadap basis data kustom kami yang besar menggunakan `hmmsearch` dan parameter “-Z 1000000”. Semua hit yang memenuhi $E < 1 \times 10^{-6}$ dengan setidaknya satu pHMM dipertahankan. Hanya hit yang memiliki panjang setidaknya 300 aa dan mencakup lebih dari 80% pHMM yang dipertahankan. Untuk semua hit terhadap suatu pHMM tertentu, hanya protein yang berada dalam 99% tengah distribusi ukuran yang dipertahankan. Lokus genetik yang bersesuaian diekstraksi dari basis data, termasuk 8.192 nukleotida sekuens pengapit pada kedua ujung 5' dan 3' dari CDS efektor Cas. Peranti lunak `minced` digunakan untuk mengidentifikasi larik CRISPR dalam sekuens pengapit menggunakan parameter “-minRL 18 -maxRL 50 -minSL 18 -maxSL 50” (?). Hanya lokus yang memiliki efektor Cas yang diprediksi dan larik CRISPR yang dipertahankan. Lokus CRISPR/Cas akhir diekstraksi dengan terlebih dahulu mengidentifikasi subsekuens yang mencakup efektor Cas dan larik CRISPR, lalu menyertakan nukleotida pengapit tambahan pada kedua sisi hingga tersisa 8.192 untuk keperluan fine-tuning. Hanya 1 lokus per kelompok Cas dengan identitas 90% yang dipertahankan, dikelompokkan menggunakan perintah `MMseqs2 “easy-cluster --cluster-reassign --cluster-mode 0 --cov-mode 0 -c 0.7 --min-seq-id 0.9”` (Steinegger dan Söding, 2017).

Untuk menyusun lokus IS200/IS605, basis data khusus ini ditelusuri menggunakan model pHMM Pfam Y1 HUH Transposase (ID Pfam: PF01797). pHMM ini mengidentifikasi protein TnpA IS200/IS605. Semua kecocokan yang memenuhi nilai $E < 1 \times 10^{-6}$, mencakup setidaknya 80% pHMM, dan memiliki panjang kurang dari 400 aa dipertahankan. Sebanyak 8.196 nt sekuens pengapit CDS kemudian diekstraksi untuk setiap kecocokan. Lokus yang juga mengandung sekuens pengkode TnpB diidentifikasi menggunakan pHMM yang telah disusun sebelumnya (Altae-Tran et al., 2023), serta pHMM khusus yang disusun menggunakan `jackhmmer` dengan TnpB ISDra2 sebagai kueri awal terhadap basis data protein MGnify, diikuti dengan penyejajaran MAFFT dari kecocokan dan konstruksi pHMM menggunakan `HMMER` (Finn et al., 2011; Mitchell et al., 2020; Katoh et al., 2002). Kecocokan dengan panjang antara 250 dan 650 aa dipertahankan, dan hanya lokus dengan jarak antara awal dan akhir sekuens TnpA dan TnpB kurang dari 2.500 nt yang dipertahankan. Untuk lokus yang hanya mengandung TnpA, hingga 300 nt sekuens pengapit ditambahkan pada kedua sisi CDS. Untuk lokus TnpA + TnpB, hingga 300 nt ditambahkan pada sisi TnpA dari elemen IS200/IS605, sedangkan 600 nt ditambahkan pada sisi TnpB (untuk memperhitungkan keberadaan ω RNA). Hanya 1 lokus per klasta TnpA dengan identitas 90% yang dipertahankan.

B.3. Prosedur pelatihan

Kami melakukan praplatihan Evo dalam dua tahap, pertama dengan ukuran konteks 8k token, diikuti oleh tahap kedua di mana kami meningkatkan ukuran konteks menjadi 131k token. Praplatihan panjang sekuens multi-tahap telah terbukti mengurangi jumlah keseluruhan jam komputasi yang diperlukan untuk melatih model konteks panjang (Xiong et al., 2023). Secara total, kami melatih Evo pada tahap 1 menggunakan 64 GPU Nvidia H100 dan pada tahap 2 menggunakan 128 GPU Nvidia A100. Secara total, Evo dilatih pada sekitar 340 miliar token, menggunakan sekitar 2×10^{22} FLOPS. Untuk tugas-tugas pembangkitan spesifik, kami selanjutnya melakukan fine-tuning Evo, seperti yang dijelaskan pada bagian-bagian berikutnya. Kami juga melaporkan penskalaan perplexity konteks panjang Evo 131k pada Gambar S2. Detail tambahan tentang pelatihan disediakan pada Tabel S2.

DPemuatan data Kami menggunakan pengemasan sekuens untuk menghasilkan sampel pelatihan, di mana beberapa sekuens DNA a...tambahkan hingga panjang konteks (8k atau 131k) tercapai. Sekuens DNA individual dipisahkan oleh akhir-otoken f-sequence (EOS). Bergantung pada dataset atau tugas, kami juga menambahkan di depan kelas khusus (CLS) token untuk mengondisikan model, misalnya, untuk mengarahkan pembangkitannya melalui prompting.

Penyetelan Hiperparameter dan Perbandingan Model Langsung Sebelum melatih Evo, kami melakukan penyetelan hiperparameter pada model Transformer 7B yang dilatih sebagian++ (lihat B.4) dan membandingkannya dengan model Hyena dan StripedHyena berukuran serupa. Secara khusus, kami melakukan penyapuan terhadap batch size, learning rate, dan detail arsitektur lainnya. Bahkan ketika mengontrol iterasi pelatihan alih-alih komputasi (FLOPS), kinerja Transformer++ secara substansial lebih buruk daripada StripedHyena (lihat S4). Di antara semua baseline, kami menemukan bahwa StripedHyena mencapai perplexity terendah secara keseluruhan pada skala 7B, konsisten dengan laju penskalaan yang disajikan di Gambar 1G.

B.4. Hukum Penskalaan

We membandingkan berbagai kelas arsitektur melalui protokol komputasi-optimal, yang bertujuan untuk mengevaluasi hasil pada *compute-optimal frontier*. Analisis optimal komputasi mengkaji kinerja terbaik dari suatu proses pra-pelatihan diberikan anggaran komputasi, biasanya dinyatakan dalam operasi floating point (FLOPs), dan dicapai secara optimal

mengalokasikan sebagian anggaran komputasi ke ukuran model dan ukuran dataset. Jenis arsitektur berbeda dalam efisiensi komputasi, serta cara mereka mengalokasikan anggaran komputasi ini.

Kami memulai dengan menyetel hiperparameter seperti laju pembelajaran dan ukuran batch untuk Transformer++ melalui pencarian grid, kemudian menggunakan nilai yang sama untuk semua arsitektur kecuali pada pengaturan di mana ketidakstabilan numerik teramati. Untuk mengatasi ketidakstabilan, kami menurunkan laju pembelajaran secara bertahap dan mengulangi eksperimen hingga tercapai konvergensi. Pada semua eksperimen, kami melatih model dengan panjang konteks 8.192 token. Untuk setiap anggaran komputasi yang ditentukan oleh jumlah FLOP total, kami memvariasikan ukuran model (6 juta hingga 1 miliar parameter) dan jumlah token yang dilatih. Untuk mengukur kinerja model, kami menggunakan metrik perplexity, yang menunjukkan seberapa baik suatu model autoregresif dalam memprediksi token berikutnya dari suatu sekuens dan sangat berkorelasi dengan kinerja pada tugas hilir. Nilai perplexity yang lebih rendah menunjukkan kinerja yang lebih baik.

Sprosedur hukum penskalaan Kami menyajikan ringkasan langkah-langkah yang terlibat dalam analisis hukum penskalaan kami. Quantifying laju penskalaan memungkinkan kita memprediksi kinerja seiring pertumbuhan ukuran model, ukuran dataset, dan komputasi.

1. Definisikan serangkaian anggaran komputasi yang akan dikaji. Kami menggunakan 8×10^{18} , 2×10^{19} , 4×10^{19} , dan 8×10^{19} FLOPS.
2. Hitung FLOPS (operasi titik mengambang) yang diperlukan untuk memproses ukuran maksimum tetap untuk arsitektur model yang diminati (yaitu "biaya" penggunaan model).
3. Identifikasi alokasi optimal-komputasi model untuk setiap anggaran komputasi: (a) Pilih rentang ukuran model yang luas, dan hitung untuk setiap ukuran model jumlah token yang sesuai yang perlu diproses untuk mencapai anggaran komputasi. Hiperparameter lainnya dipilih sesuai Tabel S1. Kami secara umum mengamati bahwa perubahan kecil pada topologi model (kedalaman, lebar) hanya berdampak minimal pada perplexitas, menyelaraskan hasil kami dengan temuan yang disajikan oleh Kaplan et al. (2020) untuk Transformer. (b) Latih model dengan setiap ukuran dan catat kinerjanya (misalnya, dalam hal perplexitas). (c) Identifikasi alokasi komputasi optimal: Mengikuti analisis sebelumnya, kami menyesuaikan polinomial orde kedua sebagai fungsi dari (log) ukuran model terhadap perplexitas, dan memperoleh titik optimal-komputasi sebagai nilai minimumnya. Titik optimal-komputasi mengidentifikasi alokasi optimal ukuran model dan token pelatihan pada anggaran komputasi yang diberikan.

Setelah menurunkan laju penskalaan optimal komputasi (Gambar 1G), kami membandingkan arsitektur dan alokasi optimal komputasi dari token dan ukuran model (Gambar S5). Pada Gambar S3, kami juga menunjukkan laju untuk ukuran model suboptimal komputasi berdasarkan arsitektur. Secara khusus, kami mengukur dampak pada penskalaan perplexitas yang disebabkan oleh alokasi anggaran komputasi yang suboptimal terhadap ukuran model atau set data (misalnya, melatih model yang lebih kecil untuk jumlah token yang lebih banyak). Kami memperkirakan ukuran model optimal komputasi untuk setiap anggaran komputasi, lalu menguranginya sebesar persentase (*offset*). Perplexitas yang sesuai diperoleh melalui kurva IsoFLOP (Gambar 1F). Penskalaan perplexitas Transformer++ menurun dengan cepat di luar batas optimal komputasi, berbeda dengan Hyena dan StripedHyena. Rincian arsitektur model yang dilatih untuk analisis hukum penskalaan kami disediakan dalam Tabel S1.

Transformer++ Kami menggunakan arsitektur Transformer modern decoder-only dengan penyematan posisi rotary (Siu et al., 2024), pra-norma dengan normalisasi lapisan akar rata-rata kuadrat, dan SwiGLU sebagai pencampur kanal. Lebar dalam SwiGLU adalah 4/3 kali lebar model. Kami bereksperimen dengan attention kueri-berkelompok (GQA) (Ainslie et al., 2023) dan menemukan perbedaan minimal pada loss akhir, yang menunjukkan bahwa teknik ini mungkin cocok untuk pemodelan sekuens DNA, guna lebih mengurangi jejak memori selama inferensi. Semua hasil penskalaan dengan Transformer++ tidak menggunakan GQA.

Hyena Dasar Hyena dirancang dengan penyempurnaan arsitektur yang sama yang diterapkan pada model Transformer++. Kami mengganti semua lapisan self-attention multi-kepala dengan lapisan hyena, dan menggunakan parametrisasi kanonik modal untuk konvolusi panjang, dengan dimensi keadaan 8.

Mamba Kami menggunakan implementasi Mamba sebagaimana disediakan oleh para penulis di repositori publik.

B.5. Menghasilkan Sekuens DNA dengan Evo

Kami mengambil sampel sekuens dari Evo menggunakan metode standar top- k dan berbasis suhu untuk model autoregresif. Evo diuntungkan oleh mode rekuren cepat dari lapisan hyena, yang memungkinkan latensi dan biaya memori yang lebih rendah (Massaroli et al., 2024; Poli et al., 2023b). Secara khusus, kami menggunakan bentuk rekuren dari bentuk kanonis modal seperti yang ditunjukkan pada (Massaroli et al., 2024), pertama-tama memproses prompt dengan Transformasi Fourier Cepat yang dimodifikasi untuk mengembalikan keluaran dan keadaan. Kami menggunakan cache untuk keadaan dari konvolusi pendek. Evo dapat menghasilkan sekuens hingga 650.000 nukleotida pada satu GPU 80 GB, berbeda dengan metode konteks panjang lainnya untuk Transformer padat yang memerlukan jumlah node yang lebih besar. Kami menggunakan cache kv standar untuk lapisan atensi rotari di StripedHyena.

Cgenerasi yang dapat dikendalikan. Kami mengikuti teknik prompting model bahasa standar yang mengondisikan generation pada prefiks yang diberikan. Untuk pembangkitan bersyarat kelas, kami memberikan prompt dengan satu token, mewakili yang c kelas, atau tipe urutan genomik (mis. sistem Cas, IS200/605). Model juga dapat diarahkan melalui prompting on subsekuens DNA yang diinginkan.

B.6. Evaluasi multimodal

B.6.1. Protein function prediction

WKami menggunakan dataset DMS untuk menguji kinerja model bahasa protein dan nukleotida dalam kemampuannya memprediksi efek fungsional pada fungsi protein. Dalam semua kasus, kami menggunakan sekuens nukleotida yang dilaporkan oleh studi asli apenulis. Kami membatasi analisis kami pada *E. coli* dan protein manusia, di mana informasi protein *E. coli* terkandung idalam dataset pelatihan Evo tetapi di mana protein manusia tidak ada.

Untuk mengompilasi informasi nukleotida dari *E. coli* studi DMS, kami menggunakan semua set data yang tercantum dalam tolok ukur ProteinGym yang juga memiliki informasi tingkat nukleotida yang dilaporkan oleh penulis studi aslinya. Ini menghasilkan enam studi: sebuah studi DMS β -laktamase oleh Firnberg dkk. (2014), sebuah studi DMS β -laktamase oleh Jacquier dkk. (2013), sebuah studi DMS CcdB oleh Adkar dkk. (2012), sebuah set data termostabilitas multiprotein oleh Tsuboyama dkk. (2023), sebuah studi DMS IF-1 oleh Kelsic dkk. (2016), dan sebuah studi DMS Rnc oleh Weeks dan Ostermeier (2023).

Untuk mengompilasi informasi nukleotida dari studi DMS manusia, kami mempersempit cakupan himpunan set data yang digunakan dalam tolok ukur manusia kami menjadi set data manusia yang digunakan oleh Livesey dan Marsh (2023) untuk mengetok ukur prediktor efek mutasi. Kami juga membatasi analisis hanya pada studi yang menyediakan informasi tingkat nukleotida yang dilaporkan oleh penulis studi aslinya. Hasilnya adalah enam studi: studi DMS CBS oleh Sun dkk. (2020), studi DMS GDI1 oleh Silverstein dkk. (2022), studi DMS PDE3A oleh Garvie dkk. (2021), studi DMS P53 oleh Kotler dkk. (2018), studi DMS P53 oleh Giacomelli dkk. (2018), dan studi DMS BRCA1 oleh Findlay dkk. (2018).

Kami membandingkan Evo (dilatih dengan konteks 8k) dengan tiga model bahasa nukleotida: GenSLM 2,5B, yang dilatih dengan kosakata kodon pada kumpulan gen dari organisme prokariotik (Zvyagin et al., 2023); Nucleotide Transformer 2B5_multi_species, yang dilatih dengan kosakata nukleotida 6-mer pada sekuens genom dari spesies prokariotik dan eukariotik (Dalla-Torre et al., 2023); dan RNA-FM, yang dilatih dengan kosakata nukleotida tunggal pada sekuens ncRNA pendek (Chen et al., 2022). Kami juga membandingkan Evo dengan beberapa model bahasa protein yang dilatih pada korpus sekuens protein yang generik dan tidak redundan: CARP 640M (Yang et al., 2024), ESM-1v (Meier et al., 2021), ESM-2 650M, ESM-2 3B (Lin et al., 2023), ProGen2 large, dan ProGen2 xlarge (Madani et al., 2023). Untuk studi yang menyediakan model dengan berbagai ukuran parameter, kami memilih ukuran terbesar yang memungkinkan kami melakukan inferensi dengan GPU Nvidia H100 80 GB pada sekuens dari semua studi tolok ukur kami tanpa melampaui memori GPU. Kami juga menyertakan ESM-2 650M dan ProGen2 large karena model-model ini terkadang menunjukkan kinerja yang lebih baik dalam prediksi fungsi dibandingkan dengan varian yang lebih besar dari model tersebut (Notin et al., 2023).

Untuk membandingkan model bahasa nukleotida dan protein, kami menggunakan semua sekuens nukleotida unik dan nilai fitness yang terkait seperti yang dilaporkan oleh studi asli. Sekali waktu, kami mengamati bahwa nilai fitness yang dilaporkan untuk sekuens nukleotida berbeda dengan nilai fitness yang dilaporkan untuk sekuens protein; dalam kasus seperti itu, kami menggunakan nilai fitness yang dilaporkan untuk sekuens nukleotida dan mengevaluasi model bahasa protein menggunakan sekuens hasil translasi. Dalam kasus di mana terdapat beberapa sekuens nukleotida untuk satu sekuens protein akibat perbedaan penggunaan kodon, model bahasa nukleotida dievaluasi pada setiap sekuens nukleotida unik dan model bahasa protein dievaluasi pada sekuens pengkode yang sesuai dengan

esetiap sekuens nukleotida unik; ini berarti bahwa suatu model bahasa protein mungkin telah dievaluasi pada sekuens protein beberapa kali untuk suatu studi tertentu. Beberapa studi melaporkan nilai kebugaran untuk mutasi yang melibatkan kodon stop; dalam kasus seperti itu, kami mengevaluasi model bahasa nukleotida pada sekuens yang mengandung tkodon stop dan mengecualikan contoh-contoh ini dari tolok ukur model bahasa protein.

Kami menghitung korelasi Spearman antara nilai fitness eksperimental dan likelihood sekuens (untuk model bahasa autoregresif) atau pseudolikelihood sekuens (untuk model bahasa bertopeng). Kami menilai signifikansi statistik koefisien korelasi Spearman di bawah hipotesis nol bahwa koefisien korelasi tersebut berasal dari distribusi t dengan derajat kebebasan $N - 2$, di mana N adalah jumlah sampel yang digunakan untuk menghitung korelasi. Kami menggunakan distribusi nol ini untuk menghitung nilai P berdasarkan korelasi yang teramati. Kami menggunakan pustaka Python scipy (<https://scipy.org/>) untuk menghitung nilai-nilai tersebut.

B.6.2. ncRNA function prediction

Kami menggunakan dataset DMS untuk mengukur kinerja model bahasa protein dan nukleotida berdasarkan kemampuannya dalam memprediksi efek mutasi pada fungsi ncRNA. Mengingat belum adanya dataset benchmark yang mapan untuk prediksi fungsi ncRNA, kami melakukan kurasi literatur untuk mencari contoh eksperimen pemindaian mutasi ncRNA. Kami memperoleh dataset berikut: DMS ribozim oleh Kobori et al. (2015), DMS ribozim oleh Andreasson et al. (2020), DMS tRNA oleh Domingo et al. (2018), DMS tRNA oleh Guy et al. (2014), DMS ribozim oleh Hayden et al. (2011), DMS ribozim oleh Pitt dan Ferré-D'Amaré (2010), dan studi mutagenesis rRNA oleh Zhang et al. (2009).

Kami membandingkan Evo (dilatih awal dengan konteks 8k) dengan model bahasa nukleotida yang dijelaskan di atas. Serupa dengan metode yang diterapkan pada sekuens penyandi protein di atas, kami mengompilasi nilai kebugaran eksperimental untuk setiap varian ncRNA. Kami menghitung korelasi Spearman antara nilai kebugaran eksperimental dan likelihood sekuens (untuk model bahasa autoregresif) atau pseudolikelihood sekuens (untuk model bahasa bertopeng). Koefisien korelasi dan nilai P terkait dihitung seperti dijelaskan di atas.

B.6.3. Gene expression prediction from regulatory DNA

Untuk mengevaluasi kemampuan model dalam mempelajari properti DNA regulatorik, kami menggunakan set data yang dilaporkan oleh Kosuri et al. (2013) di mana satu set *E. coli* promoter dan satu set *E. coli* RBS dipasangkan secara kombinatorial dan pasangan promoter-RBS tersebut diuji secara eksperimental untuk mengukur pengaruhnya terhadap ekspresi mRNA dan protein di hilir. Kami menghitung likelihood sekuens (untuk model bahasa autoregresif) atau pseudolikelihood sekuens (untuk model bahasa bertopeng) untuk setiap pasangan promoter-RBS, dengan menggabungkan sekuens promoter secara langsung dengan sekuens RBS.

Kami menghitung nilai-nilai likelihood ini menggunakan Evo (pra-latih dengan konteks 8k) dan tiga model bahasa nukleotida lainnya yang dijelaskan di atas. Kami menggunakan nilai-nilai likelihood ini untuk memprediksi nilai ekspresi mRNA kontinu dan nilai ekspresi protein yang dibinerkan seperti yang dilaporkan dalam studi asli. Ekspresi protein dibinerkan menggunakan ambang batas di mana nilai ekspresi di atas 100.000 dianggap positif dan nilai di bawah 100.000 dianggap negatif, di mana ambang batas ini didasarkan pada distribusi bimodal nilai ekspresi protein yang dilaporkan dalam studi asli. Kami menggunakan koefisien korelasi Spearman untuk mengukur kinerja prediksi ekspresi mRNA dan AUROC untuk mengukur kinerja prediksi ekspresi protein. Kami menilai signifikansi statistik koefisien korelasi Spearman dengan nilai P yang terdistribusi t seperti yang dijelaskan di atas. Kami menilai signifikansi statistik AUROC dengan metode berbasis permutasi yang di dalamnya distribusi nol dibangun dengan mengacak label biner dan menghitung ulang AUROC subsekuens. Kami melakukan 100.000 permutasi untuk membangun distribusi nol ini.

Kami juga berusaha mengkuantifikasi seberapa baik suatu pasangan promoter-RBS tertentu terwakili dalam data pelatihan Evo, karena kami berhipotesis bahwa pasangan promoter-RBS yang lebih sering terlihat di alam, dan dengan demikian memiliki kemungkinan model bahasa yang lebih tinggi, juga merupakan pasangan yang lebih mungkin menghasilkan ekspresi gen yang lebih tinggi. Kami mencoba menyelaraskan sekuens promoter-RBS terhadap sekuens genom bakteri menggunakan tiga metode. Pertama, kami membangun basis data BLAST untuk seluruh GTDB menggunakan perintah `makeblastdb` dengan parameter default (Ye et al., 2006). Kami kemudian menggunakan perintah `blastn` dengan parameter default di mana untuk setiap pasangan promoter-RBS kami menanyakan basis data tersebut untuk hasil signifikan. Kami menggunakan jumlah hasil BLAST yang dikembalikan untuk memberi skor pada setiap pasangan promoter-RBS (tidak ada hasil diberi skor nol). Kedua, kami menggunakan `mmseqs` untuk membangun basis data dari himpunan pasangan promoter-RBS dan dari seluruh GTDB menggunakan perintah `mmseqs createdb`

(`--dbtype 2`) untuk membuat basis data nukleotida. Kami kemudian menggunakan `mmseqs createindex` (`--search-type 3`) untuk membuat indeks pencarian nukleotida. Selanjutnya, kami melakukan pencarian `all-by-all` (`--cov-mode 2`) untuk mencari sekuens di GTDB yang menyelaraskan dengan kueri promotor-RBS. Kami menggunakan jumlah penjajaran signifikan untuk memberi skor pada setiap pasangan promotor-RBS (pasangan yang tidak memiliki penjajaran diberi skor nol). Ketiga, kami mencoba menyelaraskan sekuens promotor-RBS terhadap genom referensi *E. coli* (RefSeq: GCF_000005845.2) menggunakan `bowtie2`. Kami menggunakan `bowtie2-build` dengan parameter bawaan untuk membangun indeks pada genom *E. coli*. Kami kemudian memperlakukan pasangan promotor-RBS sebagai bacaan tidak berpasangan dalam berkas FASTA dan mengaktifkan `multimapping` dengan bendera `-a` pada `bowtie2`. Kami menggunakan jumlah penjajaran untuk memberi skor pada setiap pasangan promotor-RBS (pasangan yang tidak memiliki penjajaran diberi skor nol). Kami menggunakan koefisien korelasi Spearman untuk mengukur kinerja prediktif ekspresi mRNA dan AUROC untuk mengukur kinerja prediktif ekspresi protein serta melaporkan nilai korelasi tertinggi di antara ketiga metode yang dicoba.

B.7. Penyempurnaan CRISPR-Cas, generasi, dan analisis hilir

Untuk menghasilkan sistem CRISPR-Cas, kami menyempurnakan Evo dengan melanjutkan pelatihan model pratelathian konteks 8k pada set data sekuens CRISPR-Cas, yang dikurasi seperti dijelaskan di atas. Kami mempertahankan sebagian besar hiperparameter yang digunakan selama pratelathian namun mengatur ukuran tumpak menjadi 524k token dan laju pembelajaran awal sebesar 0,00009698, yang merupakan laju pembelajaran pada langkah terakhir pratelathian. Selama pratelathian, kami menambahkan di awal satu token kelas yang sesuai dengan jenis protein Cas (Cas9, Cas12, atau Cas13), yang diidentifikasi seperti dijelaskan di atas; token kelas ini kemudian diikuti oleh sekuens nukleotida. Kami juga memodifikasi pemuat data sehingga setiap sampel yang diberikan ke model selama pelatihan akan dimulai dengan token pertama dari sekuens CRISPR-Cas dan, jika suatu sekuens lebih pendek dari panjang konteks, kami menambahkan sekuens hingga memenuhi konteks yang tersisa (di mana penambalan tidak berkontribusi pada perhitungan loss). Hal ini memastikan bahwa setiap sampel pelatihan akan berkorespondensi dengan satu sekuens CRISPR-Cas tunggal. Kami menyempurnakan model selama sekitar 10 epoch.

Kami memberikan prompt kepada model dengan token kelas tertentu untuk setiap pembangkitan sekuens. Kami melakukan pengambilan sampel autoregresif berbasis suhu dan top-k standar (Chang dan Bergen, 2023). Dalam pembangkitan kami, kami melakukan sapuan menyeluruh yang terdiri dari suhu 0,1, 0,3, 0,5, 0,7, 0,9, 1,0, dan 1,3, serta nilai top-k 2 dan 4. Semua sekuens yang diambil sampelnya kemudian digabungkan ke dalam satu berkas dan digunakan untuk ekstraksi dan analisis hilir kandidat sistem CRISPR.

Pipa evaluasi Cas *in silico* terdiri dari pencarian kerangka baca terbuka (ORF) awal menggunakan Prodigal (Hyatt et al., 2010) dan pemprofilan ORF yang diekstraksi selanjutnya menggunakan profil model Markov tersembunyi (HMM) untuk setiap sub tipe Cas. Sekuens sampel dengan hasil positif pHMM dengan nilai-E di bawah 1×10^{-3} dan panjang sekuens di atas ambang batas yang ditentukan dianalisis lebih lanjut menggunakan paket MinCED untuk mengidentifikasi kemungkinan rangkaian CRISPR (Bland et al., 2007). Genom yang mengandung baik ORF Cas maupun rangkaian CRISPR kemudian dikelompokkan menggunakan MMSeqs2 pada identitas sekuens 90% dan panjang cakupan minimum 75% (Steinegger dan Söding, 2017). Terakhir, sekuens representatif dari analisis pengelompokan disejajarkan dengan sekuens ORF Cas dalam data pelatihan menggunakan MMSeqs2 untuk mengukur divergensi dari dataset pelatihan.

Sekuens kandidat dipilih dari perwakilan kluster dalam berbagai desil identitas sekuens dan diproses menggunakan AlphaFold2 untuk memeriksa secara manual kemiripan struktural antargenerasi serta dengan struktur kristal SpCas9 tipe liar. Struktur Cas9 yang diprediksi disejajarkan dengan SpCas9 (PDB: 4OO8) dan kompleks gRNA-nya menggunakan ChimeraX, dan kandidat teratas dipilih untuk analisis lebih lanjut. Lobus pengenalan (REC) dan nuklease (NUC) yang mungkin dari struktur Cas9 yang disampel diberi label dengan melakukan pensejajaran sekuens berganda dengan sekuens protein SpCas9. Batas MSA dari lobus pada SpCas9 digunakan sebagai batas untuk memberi label lobus REC dan NUC pada sekuens yang disampel. CRISPRtracrRNA digunakan untuk mengekstrak sekuens tracrRNA potensial dari generasi kandidat dan dilipat bersama dengan sekuens crRNA yang diekstrak menggunakan RNAmultifold (Mitrofanov et al., 2022; Lorenz et al., 2011). Berbagai kombinasi panjang tracrRNA dan crRNA dinilai karena sekuens crRNA dan tracrRNA matang yang dihasilkan tidak langsung terlihat dari data sekuens mentah.

B.8. IS200/IS605 penyetakan halus, pembuatan, dan analisis hilir

Untuk menghasilkan sistem IS605, kami melakukan fine-tuning pada Evo dengan melanjutkan pelatihan model prabelajar dengan konteks 8k pada dataset sekuens IS200/IS605, yang dikurasi seperti diuraikan di atas. Kami mempertahankan sebagian besar hi-

parameter yang digunakan selama prapengetahuan tetapi mengatur ukuran batch menjadi 524k token dan laju pembelajaran awal 0,00009698, yang merupakan laju pembelajaran pada langkah akhir prapengetahuan. Selama prapengetahuan, kami menambahkan token awal generik di depan setiap sekuens. Kami juga memodifikasi pemuat data sehingga setiap sampel yang diberikan ke model selama pelatihan akan dimulai dengan token pertama dari sekuens IS200/IS605 dan, jika suatu sekuens lebih pendek dari panjang konteks, kami melakukan padding pada sekuens hingga mencapai konteks yang tersisa (di mana padding tidak berkontribusi pada perhitungan loss), serupa dengan strategi yang dijelaskan untuk sistem CRISPR-Cas9 di atas. Kami melakukan fine-tuning model selama sekitar 10 epoch.

Kami memberikan prompt kepada model dengan token awal untuk setiap generasi sekuens. Kami melakukan sampling autoregresif berbasis suhu dan top-k standar (Chang and Bergen, 2023). Dalam generasi kami, kami melakukan sampling menyeluruh yang terdiri dari suhu 0,1, 0,3, 0,5, 0,7, 0,9, 1,0, dan 1,3, serta nilai top-k 2 dan 4. Kami mengambil sampel total 1.004.850 sekuens.

Kami menganalisis sekuens yang dihasilkan menggunakan prodigal untuk mengidentifikasi sekuens pengkode dan protein (Hyatt et al., 2010), diikuti dengan hmmsearch ($-Z$ 1000000) menggunakan pHMM untuk mengidentifikasi sekuens TnpA dan TnpB (Finn et al., 2011), dan cmsearch ($-Z$ 4) menggunakan model kovarians yang dikembangkan dalam publikasi sebelumnya (Meers et al., 2023) untuk mengidentifikasi kandidat ω RNA (Nawrocki and Eddy, 2013). Kandidat sekuens TnpA dipertahankan jika memiliki nilai $E < 1 \times 10^{-3}$ terhadap pHMM dan jika mencakup setidaknya 50% dari pHMM. Kandidat sekuens TnpB dipertahankan jika memiliki nilai $E < 1 \times 10^{-3}$ terhadap setidaknya satu pHMM, jika mencakup setidaknya 50% dari pHMM, dan jika panjangnya antara 300 dan 600 asam amino.

Sekuens protein TnpA dan TnpB yang diprediksi disejajarkan kembali ke protein dalam set pelatihan menggunakan MM-seq2 (Steinegger dan Söding, 2017). Hasil pencocokan teratas untuk setiap protein diekstraksi dan disejajarkan secara terpisah menggunakan algoritme MAFFT-G-INS-I untuk mengestimasi identitas asam amino di sepanjang keseluruhan kedua sekuens (Katoh et al., 2002). Untuk memperhitungkan perbedaan kodon awal dan menghasilkan persentase identitas yang lebih konservatif, penyejajaran ini dipangkas hingga bagian tengah 80% dari setiap sekuens, celah di ujung-ujung dipangkas, dan identitas asam amino dihitung ulang.

Untuk lokus yang mengandung sekuens pengode TnpA dan TnpB, kami menggunakan ESMFold (Lin et al., 2023) untuk memprediksi struktur tingkat atom untuk setiap sekuens protein. Kami melaporkan pLDDT rata-rata atom kerangka utama sebagai ukuran kepercayaan prediksi ESMFold. Protein TnpA dan TnpB contoh masing-masing disejajarkan dengan struktur PDB 2EC2 dan 8BF8 menggunakan algoritme cealign di PyMOL (Schrödinger, LLC, 2015). RNAfold dari paket ViennaRNA digunakan untuk melipat ω RNA yang diprediksi dengan parameter “-d3 -P rna_langdon2018.par” (Gruber et al., 2008; Langdon et al., 2018). Kami juga menggunakan Evo untuk menghitung entropi probabilitas bersyarat pada setiap posisi dalam suatu sekuens tertentu. Sebagai contoh, entropi pada posisi i dihitung menggunakan likelihood $p(x_i|x_1, \dots, x_{i-1})$ di seluruh kosakata. Kami kemudian memvisualisasikan entropi-entropi ini bersama dengan posisi sekuens yang dianotasi untuk beberapa sistem IS200/IS605 kanonik.

B.9. Prediksi esensialitas gen

We diperoleh hasil esensialitas biner di seluruh genom untuk 56 genom bakteri dari basis data DEG (Zhang, 2004) di mana gen penyandi diberi label biner “esensial” atau “non-esensial”. Kami juga memperoleh hasil esensialitas seluruh genom untuk dua genom fag, lambda dan P1, dari Piya et al. (Piya et al., 2023) dan menggunakan label biner yang ditetapkan oleh penulis studi berdasarkan hasil skrining CRISPRi mereka.

Untuk melakukan penapisan esensialitas gen secara in silico, kami memperoleh genom bakteri lengkap menggunakan ID RefSeq yang disediakan oleh DEG. Kami menggunakan RefSeq: NC_001416 sebagai genom referensi untuk fag lambda dan RefSeq: NC_005856 sebagai genom referensi untuk fag P1. Kami mengiterasi seluruh gen yang teranotasi sebagai pengode protein dan menghitung skor dengan model bahasa nukleotida untuk setiap gen. Untuk menghitung skor, kami memberikan model bahasa tersebut berbagai tingkat konteks: (1) hanya sekuens gen, (2) sekuens gen ditambah konteks yang terdistribusi merata pada kedua sisi gen hingga total 8.192 pb, atau (3) sekuens gen ditambah konteks yang terdistribusi merata pada kedua sisi gen hingga total 65.536 pb. Jika panjang gen melebihi 8.192 pb, kami menggunakan 8.192 pb pertama dari sekuens gen. Kami menghitung skor sebagai perbedaan log-likelihood antara sekuens termutasi dan sekuens tipe liar yang tidak termutasi. Untuk memutasi sekuens, kami menyisipkan beberapa kodon stop “TAATAATAAGTGA” pada posisi 12 nukleotida ke dalam sekuens; untuk pengaturan konteks 8.192 dan 65.536 pb, kami menambahkan konteks pada kedua sisi gen setelah penyisipan. Selain itu, untuk pengaturan 8.192 pb, kami menguji dua strategi lain: (1) menyisipkan satu kodon stop “TAA” pada posisi 12 nukleotida ke dalam sekuens dan (2) menghapus seluruh sekuens gen (setelah itu kami menyediakan konteks 8.192 pb yang berpusat pada

tgen yang dihapus) (Gambar S9). Sebagai kontrol tambahan, kami juga menggunakan posisi linear gen dalam referensi genome sebagai nilai yang digunakan untuk memprediksi esensialitas. Jika model hanya menggunakan informasi posisional untuk memprediksi esensialitas, kinerjanya akan serupa dengan kontrol ini.

Kami menggunakan perubahan log-likelihood untuk memprediksi label biner esensialitas gen dan menghitung kekuatan prediksi dengan skor AUROC. Kami menilai signifikansi statistik AUROC dengan metode berbasis permutasi yang di dalamnya distribusi nol dibangun dengan melakukan permutasi pada label biner dan menghitung AUROC subsekuens. Kami melakukan 100.000 permutasi untuk membangun distribusi nol ini.

B.10. Pembangkitan dan Evaluasi Skala Genom

Kami menggunakan Evo yang dipaprelatih pada konteks 131k untuk mengambil sampel dua puluh sekuens hingga panjang ~650 kb. Kami mengambil sampel dengan suhu 0,7 dan nilai top-*k* sebesar 4, mengikuti prosedur pengambilan sampel autoregresif standar (Chang dan Bergen, 2023). Kami memberikan prompt pada model dengan empat prompt spesifik spesies, yang diperkenalkan selama paprelatihan 131k, sesuai dengan spesies bakteri *Mycoplasma genitalium*, *Staphylococcus aureus*, *Klebsiella pneumoniae*, dan *Escherichia coli*. Prompt-prompt ini mengikuti string garis keturunan ala Greengenes, yang menggabungkan semua takson dimulai dari yang paling leluhur dan diakhiri dengan yang paling terkini, dipisahkan oleh titik koma. Awalan satu karakter juga ditambahkan pada setiap takson yang menunjukkan peringkatnya. Kami mengambil sampel lima sekuens untuk setiap prompt, sehingga menghasilkan total dua puluh sekuens.


Kami mengevaluasi generasi-generasi ini dengan CheckM (Parks et al., 2015), sebuah perangkat yang menghitung metrik kualitas genom dasar berdasarkan apakah suatu urutan DNA panjang memiliki sifat-sifat yang mirip dengan genom bakteri yang diketahui. CheckM menggunakan Prodigal (Hyatt et al., 2010) untuk mengidentifikasi urutan pengkode dan menghitung kepadatan pengkode sebagai salah satu metrik kualitas genom. CheckM juga akan mencari keberadaan gen-gen yang sangat terkonservasi di sebagian besar keragaman prokariotik. Kami membagi semua generasi kami menjadi lima segmen diskret dengan panjang hingga 131.072 bp (total 100 urutan) dan menghitung distribusi kepadatan pengkode CheckM di seluruh potongan ini. Sebagai kontrol positif, kami memilih secara acak 100 genom bakteri dari GTDB dan menggunakan CheckM untuk menghitung kepadatan pengkode untuk potongan sepanjang 131.072 bp dari genom-genom ini. Sebagai kontrol negatif, kami membangkitkan 1.000 urutan dengan panjang 131.072 bp yang mana keempat pasangan basa DNA-nya diambil secara acak seragam. Kami kemudian menggunakan CheckM untuk menghitung kepadatan pengkode pada urutan acak ini. Kami juga menggunakan tRNAscan-SE untuk mencari urutan tRNA dalam urutan yang kami bangkitkan dan kami menggunakan barrnap untuk mencari urutan rRNA.

Kami menggunakan ESMFold untuk memperoleh prediksi struktur tingkat atom untuk seluruh sekuens pengkode yang didefinisikan oleh Prodigal di setiap generasi kami. Kami membatasi prediksi struktur ESMFold pada sekuens pengkode dengan panjang antara 100 hingga 1024 asam amino, inklusif. Kami menghitung rerata backbone pLDDT untuk semua struktur yang diprediksi. Kami menggunakan paket Python biotite untuk menghitung persentase elemen struktur sekunder pada semua struktur yang diprediksi. Kami menggunakan FoldSeek easy-search untuk melakukan penyesuaian berbasis TM secara efisien (--alignment-type 1), dengan semua parameter lain diatur ke nilai default, guna melakukan pencarian struktural semua terhadap semua antara struktur ESMFold yang bersesuaian dengan sekuens yang dihasilkan Evo dan prediksi struktur bagi UniRef50 yang tersedia di AlphaFold Protein Structure Database (<https://alphafold.ebi.ac.uk/>). Skor penyesuaian struktur dinilai sebagai rata-rata dari TMScore query dan TMScore target, dengan skor lebih dari 0,4 dianggap sebagai kecocokan struktural. Kami menggunakan kecocokan struktural ini, bersama dengan istilah GO yang ditetapkan pada kluster UniRef50, untuk menyimpulkan istilah GO bagi protein yang dihasilkan Evo. Kami menggunakan PyMOL untuk memvisualisasikan struktur protein yang sesuai dengan lima istilah GO “molecular function” dengan representasi terbanyak di antara protein yang dihasilkan Evo.


C. Tabel dan gambar suplemen

Table S1 | Pengaturan model hukum penskalaan untuk Transformer++, Hyena, StripedHyena, dan Mamba. Jumlah lapisan untuk Mamba digandakan (satu blok setara dengan dua lapisan Mamba dan lapisan pencampur saluran khusus dihilangkan, seperti dijelaskan dalam (Gu dan Dao, 2023)). Jumlah parameter sedikit bervariasi untuk setiap arsitektur.


PARAMS (M)	D_MODEL	GLU_SIZE	KV_SIZE	N_HEADS	N_LAYERS	LEARNING RATE
1	128	336	64	2	4	9.77E-04
6	320	848	64	5	5	9.57E-04
17	448	1200	64	7	7	9.36E-04
29	512	1360	64	8	9	9.15E-04
40	576	1536	64	8	10	8.95E-04
59	640	1696	64	10	12	8.70E-04
69	640	1712	64	10	14	8.56E-04
84	704	1872	64	11	14	8.37E-04
99	768	2048	64	12	14	8.18E-04
114	768	2048	64	12	16	8.00E-04
121	768	2048	64	12	17	7.75E-04
135	768	2048	64	12	19	7.50E-04
158	832	2224	64	13	19	7.25E-04
175	832	2224	64	13	21	7.00E-04
203	896	2384	64	14	21	6.75E-04
232	896	2384	64	14	24	6.50E-04
266	960	2560	64	15	24	6.25E-04
303	1024	2736	64	16	24	6.00E-04
383	1152	3072	64	18	24	5.66E-04
473	1280	3408	64	20	24	5.33E-04
572	1408	3760	128	11	24	5.00E-04
680	1536	4096	128	12	24	4.75E-04
798	1664	4432	128	13	24	4.55E-04
926	1792	4784	128	14	24	4.33E-04
1063	1920	5120	128	15	24	4.15E-04
1209	1920	5120	128	15	25	4.11E-04




Gambar S1 | Data prapelatihan. Statistik IMG/VR dan IMG/PR. (A) Diagram lingkaran yang menggambarkan komposisi dunia virus pada subset IMG/VR dari dataset prapelatihan. (B) Diagram lingkaran yang menggambarkan komposisi kingdom inang pada subset IMG/VR dari dataset prapelatihan. Kami mengecualikan virus yang kemungkinan besar menginfeksi inang eukariotik (Metode). (C) Distribusi panjang sekuens pada subset IMG/VR dari dataset prapelatihan. (D) Distribusi panjang sekuens pada subset IMG/PR dari dataset prapelatihan.



Gambar S2 | Penskalaan perplexitas terhadap panjang konteks. Perplexitas pada subset dari set validasi OpenGenome dengan Evo 131k sebagai fungsi dari panjang sekuens, atau panjang konteks. Perplexitas dihitung pada 2048 nukleotida terakhir dari setiap sekuens, dengan panjang prefiks yang meningkat dan dengan demikian konteks yang tersedia bagi model juga meningkat. Kami mengamati perplexitas terus menurun melampaui panjang konteks pelatihan pada 131k, yang ditunjukkan oleh garis putus-putus vertikal.



Gambar S3 | Laju penskalaan untuk ukuran model yang tidak optimal secara komputasi berdasarkan arsitektur. Kami mengukur dampak pada penskalaan perplexity yang disebabkan oleh alokasi anggaran komputasi yang tidak optimal pada ukuran model atau dataset (misalnya, melatih model yang lebih kecil untuk lebih banyak token). Kami memperkirakan ukuran model yang optimal secara komputasi (Gambar S5) untuk setiap anggaran komputasi, kemudian mengurangi dengan suatu persentase (sebesar *offset*). Perplexity yang sesuai diperoleh melalui kurva IsoFLOP (Gambar 1F). Penskalaan perplexity Transformer++ menurun dengan cepat di luar batas optimal secara komputasi, berkebalikan dengan Hyena dan StripedHyena.



Gambar S4 | Perbandingan langsung kurva rugi pelatihan selama penyetelan hiperparameter untuk model 7B. Kami menyetel beberapa model Transformer++ dan Mamba sebagai garis dasar, dengan menyapu lebar laju pembelajaran, ukuran batch, panjang sekuens, serta rasio kedalaman terhadap lebar model. Pada semua pengaturan, Hyena dan StripedHyena mengungguli Transformer++ dan Mamba, di mana kedua garis dasar tersebut mengalami ketidakstabilan selama pelatihan.





Figure S5 | Token dan ukuran model yang optimal secara komputasi per model. Alokasi optimal komputasi untuk ukuran dataset (jumlah token) dan ukuran model (jumlah parameter) untuk setiap anggaran komputasi, diukur dalam FLOPS.

TTable S2 | Pengaturan hiperparameter StripedHyena 7B pada pra-pelatihan. Hiperparameter yang digunakan untuk pra-pelatihan. at 7B ditampilkan berdasarkan tahap, di mana tahap 2 menyoroti perbedaan dari tahap 1.

Stage 1	
sequence len.	8k
batch size	4M tokens
scheduler	cosine decay
learning rate	3e-4
min. learning rate	3e-5
position emb.	RoPE (Su et al., 2024)
weight decay	0.1
weight decay in hyena layers	0.0
precision	mixed (BF16, FP32 on long convolution parameters)
optimizer	Adam
optimizer betas	0.9, 0.95
eps	1e-8
norm	RMSnorm (Zhang and Sennrich, 2019)
dropout	0.0
warmup	1% total steps
checkpoint activation	True
model_width	4096
num_attn_heads	32
hyena short conv. length	3
GLU width	4/3 model_width
vocab size	512
Stage 2	
sequence len.	131k
batch size	1M tokens
learning rate	1e-4
min. learning rate	1e-5
position emb.	linearly interpolated RoPE
interp. factor	16

TTabel S3 | Statistik ringkasan untuk dataset OpenGenome. Lihat B.2 untuk detail lebih lanjut tentang dataset ini. sumber dan proses kurasi.

Dataset Name	Source	Subset	Total Genomes/ Loci/Plasmids	Total Bases (M)	Avg Length (base)
Bacterial and Archaeal Genomes	GTDB		85,205	273,865	3,214,184
Prokaryotic Viruses	IMG/VR		2,653,046	36,236	13,658
Plasmids	IMG/PR		214,950	5,827	27,106
CRISPR/Cas Loci	Custom Database	Cas9	5,566	43	7,798
CRISPR/Cas Loci	Custom Database	Cas12	5,069	35	6,911
CRISPR/Cas Loci	Custom Database	Cas13	498	4	7,559
IS200/IS605 Loci	Custom Database	IS200 Loci	219,866	239	1,085
IS200/IS605 Loci	Custom Database	IS605 Loci	10,720	26	2,445



Gambar S6 | Kinerja Evo dalam prediksi efek mutasi untuk protein manusia. (A) Kinerja prediksi model bahasa nukleotida dan protein dalam prediksi efek mutasi untuk protein manusia, diukur melalui korelasi Spearman. Tinggi batang menunjukkan rerata; setiap titik menunjukkan studi DMS yang berbeda. LM: model bahasa; Nucl. Trans.: Nucleotide Transformer. Terkait dengan Gambar 2B. (B) Hubungan antara perplexity Evo dari sekuens nukleotida tipe liar (sumbu horizontal) dan kemampuan Evo untuk melakukan prediksi efek mutasi zero-shot bagi protein tersebut yang diukur melalui korelasi Spearman (sumbu vertikal). Setiap titik merepresentasikan protein yang berbeda; titik diwarnai berdasarkan apakah protein tersebut merupakan protein *E. coli* (teal) atau manusia (biru). Kami mengamati korelasi negatif yang kuat (Spearman $r = -0.87$) antara perplexity dan kinerja prediksi fungsi zero-shot.






Figure S7 | Perincian keragaman generasi Cas berdasarkan token prompt. Evo dapat menghasilkan lokus Cas yang beragam di berbagai sub tipe melalui pemberian prompt konvensional maupun pemberian prompt lintas tipe. Evo diberi prompt dengan token khusus “cas9”, “cas12”, atau “cas13” dan setiap kumpulan generasi yang dihasilkan dianalisis menggunakan pHMM untuk setiap sub tipe Cas Kelas 2 dan dibandingkan dengan data pelatihan untuk mengamati divergensi dari dataset pelatihan.



Gambar S8 | Analisis tambahan terhadap sekuens IS200/IS605 yang dihasilkan dan model yang disetel halus. (A) Contoh tambahan beragam protein mirip TnpA dengan domain HuH Y1 yang terdeteksi dan pLDDT rata-rata atom tulang punggung yang tinggi. Label menunjukkan persentase identitas asam amino terhadap protein terdekat yang ditemukan di set pelatihan atau NCBI nr dan pLDDT. Struktur PDB 2EC2 ditampilkan sebagai referensi. (B) Contoh beragam protein TnpB yang dihasilkan. Struktur PDB 8BF8 ditampilkan sebagai referensi. (C) Ringkasan dari 1.004.850 sekuens yang dihasilkan menggunakan model yang disetel halus pada lokus IS200/IS605. Sekuens memiliki TnpA, TnpB, atau ωRNA yang terdeteksi ("Any"), sekuens pengkode TnpA ("TnpA"), sekuens pengkode TnpB ("TnpB"), atau ωRNA ("ωRNA"). (D) Perbandingan persentase di setiap kategori antara set pelatihan dan sekuens yang dihasilkan untuk sekuens dengan sekuens pengkode TnpA dan TnpB yang terdeteksi. Kategori mencakup sekuens dengan ωRNA yang terdeteksi ("ωRNA"); sekuens yang mengkode protein TnpB dengan panjang antara 300 dan 600 aa; dan sekuens dengan TnpA, protein TnpB antara 300 dan 600 aa, dan ωRNA. (E) Entropi rata-rata dalam 250 nt dari ujung 5' dan 3' sekuens pengkode IS605, termasuk 50 nt dari CDS itu sendiri. Entropi dihitung pada setiap posisi di seluruh sekuens IS605 dalam set pelatihan ($N = 10.419$). Posisi sekuens disejajarkan terhadap awal dan akhir masing-masing CDS. (Kiri) Semua sekuens dengan TnpA diikuti oleh TnpB. (Kanan) Sekuens dengan TnpB mendahului TnpA pada untai maju. Plot abu-abu menunjukkan simpangan baku nilai entropi.



Gambar S9 | Prediksi esensialitas gen pada berbagai pengaturan. (A) Diagram sebar yang membandingkan nilai AUROC antara model atau jendela konteks yang berbeda. Label sumbu sama seperti label horizontal pada Gambar 5C. Setiap titik mewakili studi esensialitas seluruh genom yang berbeda. Terkait dengan Gambar 5C. (B) Kinerja prediksi esensialitas gen untuk 58 studi (setiap titik mewakili studi yang berbeda). Kami melakukan mutagenesis in silico pada setiap sekuens pengkode di dalam genom dan menghitung perubahan dalam likelihood Evo, yang kami gunakan untuk memprediksi esensialitas gen. “Evo (konteks 8k, multi-stop)” menunjukkan strategi mutagenesis yang menyisipkan beberapa kodon stop di awal setiap sekuens pengkode. “Evo (konteks 8k, stop tunggal)” menunjukkan mutagenesis yang menyisipkan satu kodon stop di awal setiap sekuens pengkode. “Evo (konteks 8k, deleksi)” menunjukkan strategi mutagenesis yang menghapus seluruh sekuens gen. “Prediksi berbasis posisi” menunjukkan strategi prediksi (tidak menggunakan Evo) di mana kami menggunakan posisi gen dalam anotasi genom referensi sebagai variabel prediktor untuk esensialitas gen. Lihat Metode untuk detail lebih lanjut. Terkait dengan Gambar 5C.




Figure S10 | Statistik untuk prediksi struktur ESMFold dari sekuens pengkode protein yang dihasilkan Evo. Histogram yang merepresentasikan distribusi statistik yang dihitung pada struktur yang diprediksi ESMFold. Struktur ini sesuai dengan sekuens pengkode yang ditemukan pada lima sekuens yang dihasilkan Evo, masing-masing sepanjang ~650 kb. Statistik ini, dari kiri ke kanan, adalah: persentase residu pada heliks alfa, persentase residu pada lembaran beta, pLDDT tulang punggung rata-rata, dan TMScore terhadap struktur UniRef50 terdekat di AlphaFold Protein Structure Database sebagaimana ditentukan oleh FoldSeek easy-search.